

Эконометрика межобъектных данных

Практические упражнения

Турунцева М.Ю. Зямалов В.Е. Галеева Е.А.
Кириллова М.А.

Оглавление

3	Парная регрессия	1
	Практическое упражнение №1	1
	R	1
	Python	5
	Практическое упражнение №2	12
	R	13
	Python	15
5	Тестирование гипотез	19
	Практическое упражнение №1	19
	R	19
	Python	23
	Практическое упражнение №2	28
	R	28
	Python	31
6	Гетероскедастичность	35
	Практическое упражнение	35
	R	35
	Python	43
8	Множественная регрессия	53
	Практическое упражнение	53
	R	54
	Python	59
9	Контрольные переменные	67
	Практическое упражнение №1	67
	R	68
	Python	72
	Практическое упражнение №2	76

R	77
Python	80
Практическое упражнение №3	82
R	83
Python	84
10 Нелинейные регрессионные модели	87
Практическое упражнение №1	87
R	88
Python	97
Практическое упражнение №2	106
R	107
Python	114
Список литературы	123

Тема 3 Модель парной линейной регрессии.

МНК

Практическое упражнение №1

Возвращаемся к задаче (1) и используем для анализа данных средства эконометрических пакетов (EViews и т.д.).

- Создайте рабочий файл.

Для каждого набора данных:

- Сгенерируйте ряды значений x и y .
- Образуйте группу, состоящую из рядов x и y .
- Постройте диаграмму рассеяния.
- Найдите коэффициент корреляции между рядами x и y .
- Оцените модель $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$ и получите ряд прогнозных значений $\hat{y}_i$ (используя Forecast).
- Создайте группу из рядов x , y и $\hat{y}_i$. Постройте график зависимости y и $\hat{y}$ от x (диаграмма рассеяния с подобранной прямой). Проверьте, что тот же график получается при использовании «scatter with regression» в группе, состоящей из рядов x и y .
- Вычислите коэффициенты «обратной» модели и на их основе получите значения y_i^* , вычисляемые для значений x_i с использованием подобранной «обратной» модели.
- Создайте группу из рядов x , y , $\hat{y}$ и y^* .
- Постройте график зависимости y , $\hat{y}$ и y^* от x . Обратите внимание на раскрытые «ножницы».

R

В R нам необязательно импортировать пакеты перед их использованием, так как функцию из пакета можно вызвать при помощи оператора `::`. Но иногда удобнее это все-таки сделать; например, стиль работы с пакетами из набора `tidyverse` предполагает постоянный вызов функций из этих пакетов.

Сгенерируем x и y длины 150. x будет последовательностью от 0 до 149, $y = 1 + 0.5x + u_i$. Ошибка u_i будет иметь распределение $u_i \sim N(0, 100)$

R

```
N <- 150  
x <- 0:(N - 1)  
y <- 1 + .5 * x + rnorm(N, sd = 10)
```

Посмотрим на коэффициент корреляции между ними.

R


```
cor(x, y)
```

```
## [1] 0.9897187
```

Построим диаграмму рассеяния.

R

```
plot(y ~ x)
```



Оценим модель парной регрессии y на x .

R

```
model <- lm(y ~ x)  
summary(model)
```

```
##
## Call:
## lm(formula = y ~ x)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -28.7913  -7.2776   0.1708   6.0493  23.7172
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  0.33341     1.68528   0.198   0.843
## x            0.52126     0.01956  26.652 <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 10.37 on 148 degrees of freedom
## Multiple R-squared:  0.8276, Adjusted R-squared:  0.8264
## F-statistic: 710.3 on 1 and 148 DF, p-value: < 2.2e-16
```

Получим $\hat{y}_i$.


R

```
yh <- predict(model)
```

Построим график y и $\hat{y}$ от x .

R

```
plot(y ~ x)
lines(yh ~ x, col = "blue")
```



Оценим «обратную» модель и получим $y_i^* := \hat{x}_i$.

R


```
imodel <- lm(x ~ y)
xh <- predict(imodel)
summary(imodel)
```

```
##
## Call:
## lm(formula = x ~ y)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -40.672 -12.781   0.958  11.658  41.828
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 12.31642    2.76188   4.459 1.61e-05 ***
## y           1.58765    0.05957  26.652 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 18.1 on 148 degrees of freedom
## Multiple R-squared:  0.8276, Adjusted R-squared:  0.8264
## F-statistic: 710.3 on 1 and 148 DF,  p-value: < 2.2e-16
```

Построим график зависимости y , $\hat{y}$ и y^* от x .

R

```
plot(y ~ x)
lines(yh ~ x, col = "blue")
lines(y ~ xh, col = "red")
```

Обратите внимание, что функции `plot` и `lines` используют точки в порядке их следования в массивах, поэтому иногда вам может потребоваться сортировка данных перед построением графика.

Python

В python мы **должны** импортировать все что нам нужно до начала работы. Импортируем модули для загрузки данных и оценивания моделей.

Для того, чтобы заставить `numpy` выводить числа как числа, а не как `np.float64(...)`, установим `legacy` формат печати чисел.

Python

```
import numpy as np
import pandas as pd
import statsmodels.api as sm

np.set_printoptions(legacy="1.21")
```

Также нам нужно будет строить графики, поэтому импортируем `matplotlib`.

Python

```
import matplotlib.pyplot as plt
import seaborn as sb

plt.rcParams["figure.figsize"] = (5,5)
```

Сгенерируем x и y длины 150. x будет последовательностью от 0 до 149, $y = 1 + 0.5x + u_i$. Ошибка u_i будет иметь распределение $u_i \sim N(0, 100)$

Python

```
N = 150

u = np.random.normal(scale=10, size=N)
x = np.array(range(150))
y = 1 + .5 * x + u
```

Посмотрим на коэффициент корреляции между ними.

Python


```
np.corrcoef(x, y)
```

```
## array([[1.          , 0.89218397],
##        [0.89218397, 1.          ]])
```

Построим диаграмму рассеяния.

Python

```
plt.scatter(x, y)
plt.show()
```



Оценим модель парной регрессии y на x . Для начала создадим объект, описывающий регрессию, затем вызовем его метод `fit`.

В отличие от `scikit-learn`, `fit` не меняет внутреннего состояния объекта, а возвращает новый объект!

Создаем объект и оцениваем модель.

Python

```
df_ = sm.add_constant(x)
model = sm.OLS(y, df_)
model_est = model.fit()
print(model_est.summary())
```

```
##                               OLS Regression Results
## =====
## Dep. Variable:                y    R-squared:                0.796
## Model:                      OLS    Adj. R-squared:          0.795
## Method:                    Least Squares    F-statistic:          577.5
## Date:                      Cp, 02 июл 2025    Prob (F-statistic):    6.01e-53
## Time:                      21:40:13    Log-Likelihood:       -572.87
## No. Observations:          150    AIC:                  1150.
## Df Residuals:              148    BIC:                  1156.
## Df Model:                   1
## Covariance Type:           nonrobust
## =====
##               coef    std err          t      P>|t|      [0.025    0.975]
## -----
## const          1.1606      1.804      0.644      0.521     -2.403      4.725
## x1              0.5030      0.021     24.030      0.000      0.462      0.544
## =====
## Omnibus:                 0.116    Durbin-Watson:          1.773
## Prob(Omnibus):           0.944    Jarque-Bera (JB):        0.159
## Skew:                    0.065    Prob(JB):                0.924
## Kurtosis:                2.908    Cond. No.:               171.
## =====
##
## Notes:
## [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
```

Данный метод крайне неудобен, так как надо:

1. вручную создавать матрицы,
2. вручную добавлять константу.

На взгляд авторов оптимальным способом является следующий. Создадим датафрейм, содержащий наши данные, создадим объект с моделью и оценим ее.

Python

```
df = pd.DataFrame({"x": x, "y": y})
model = sm.OLS.from_formula("y ~ x", data=df)
model_est = model.fit()
```

Посмотрим на оценки.

Python

```
print(model_est.summary())
```

```
##                               OLS Regression Results
## =====
## Dep. Variable:                  y   R-squared:                  0.796
## Model:                        OLS   Adj. R-squared:            0.795
## Method:                    Least Squares   F-statistic:                577.5
## Date:                Ср, 02 июл 2025   Prob (F-statistic):        6.01e-53
## Time:                21:40:13   Log-Likelihood:            -572.87
## No. Observations:                150   AIC:                        1150.
## Df Residuals:                    148   BIC:                        1156.
## Df Model:                        1
## Covariance Type:                nonrobust
## =====
##               coef    std err          t      P>|t|      [0.025    0.975]
## -----
## Intercept      1.1606      1.804      0.644      0.521     -2.403     4.725
## x              0.5030      0.021     24.030      0.000      0.462     0.544
## =====
## Omnibus:                0.116   Durbin-Watson:            1.773
## Prob(Omnibus):          0.944   Jarque-Bera (JB):          0.159
## Skew:                   0.065   Prob(JB):                  0.924
## Kurtosis:               2.908   Cond. No.                  171.
## =====
##
## Notes:
## [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
```

Получим $\hat{y}_i$.


Python

```
yh = model_est.predict()
```

Построим график y и $\hat{y}$ от x .

Python


```
plt.scatter(x, y)  
plt.plot(x, yh, color="red")  
plt.show()
```



Или одной командой без промежуточных вычислений.

Python

```
sb.regplot(x=x, y=y, ci=None)  
plt.show()
```



Оценим «обратную» модель и получим $y_i^* := \hat{x}_i$.

Python

```
imodel = sm.OLS.from_formula("x ~ y", data=df)
imodel_est = imodel.fit()
xh = imodel_est.predict()

print(imodel_est.summary())
```

```

##                                OLS Regression Results
## =====
## Dep. Variable:                  x    R-squared:                  0.796
## Model:                        OLS    Adj. R-squared:             0.795
## Method:                      Least Squares    F-statistic:             577.5
## Date:                        Ср, 02 июл 2025    Prob (F-statistic):      6.01e-53
## Time:                        21:40:14    Log-Likelihood:          -658.84
## No. Observations:             150    AIC:                     1322.
## Df Residuals:                 148    BIC:                     1328.
## Df Model:                     1
## Covariance Type:              nonrobust
## =====
##               coef      std err          t      P>|t|      [0.025      0.975]
## -----
## Intercept    13.3618      3.010      4.440      0.000      7.415     19.309
## y            1.5826      0.066     24.030      0.000      1.452      1.713
## =====
## Omnibus:                0.190    Durbin-Watson:             1.412
## Prob(Omnibus):          0.909    Jarque-Bera (JB):          0.300
## Skew:                   -0.077    Prob(JB):                  0.861
## Kurtosis:               2.844    Cond. No.:                  85.6
## =====
##
## Notes:
## [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

```


Построим график зависимости y , $\hat{y}$ и y^* от x .

Python

```

plt.scatter(x, y)
plt.plot(x, yh, color="red")
plt.plot(xh, y, color="green")
plt.show()

```



Практическое упражнение №2

(СУ, E4.1) Воспользуйтесь файлом с данными **CPS12**¹, который содержит расширенную версию множества данных, использованных в таблице 3.1 для 2012 года. Он содержит данные по работникам в возрасте от 25 до 34 лет, работающим полный рабочий в течение года и имеющим диплом о высшем образовании или В.А./B.S степени. Детальный комментарий к данным дан в файле **CPS12_Description** (это те же самые данные, как в **CPS92_12**, но ограниченные 2012 годом). В этом упражнении вы будете исследовать взаимосвязь между возрастом работника и его зарплатой (как правило, старшие работники имеют больший опыт работы, что влечет за собой более высокие производительность труда и зарплату).

- а. Оцените регрессию средней почасовой зарплаты (AHE) на возраст (Age). Чему равна оцененная константа? А чему оцененный угловой коэффициент? Используйте оцененную регрессию, чтобы ответить на этот вопрос: как сильно увеличится зарплата при увеличении возраста на 1 год?
- б. Боб является 26-летним работником. Предскажите зарплату Боба, ис-

¹Этот и другие необходимые файлы можно загрузить по ссылке: https://www.princeton.edu/~mwatson/Stock-Watson_3u/Students/EE_Datasets/

- пользуя оцененную регрессию. Алексис является 30-летним работником. Предскажите зарплату Алексис, используя оцененную регрессию.
- в. Учитывает ли возраст большую долю в дисперсии зарплат в выборке? Объясните.

R

Скачаем файл `cps12.xlsx` и загрузим его:

R

```
dataset <- readxl::read_excel("data/cps12.xlsx")
head(dataset)
```

```
## # A tibble: 6 x 5
##   year   ahe bachelor female  age
##   <dbl> <dbl>   <dbl>   <dbl> <dbl>
## 1  2012 19.2         0       0    30
## 2  2012 17.5         0       0    29
## 3  2012  8.55        0       0    27
## 4  2012 16.8         0       1    25
## 5  2012 16.3         1       1    27
## 6  2012 16.1         1       0    30
```

Оценим регрессию средней почасовой зарплаты (*AHE*) на возраст (*Age*). Обратите внимание, что данные берутся из заданного нами датасета.

R

```
model <- lm(ahe ~ age, data = dataset)
summary(model)
```

```
##
## Call:
## lm(formula = ahe ~ age, data = dataset)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -19.864  -7.381  -2.245   4.799  72.499
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  4.62605    1.28752   3.593 0.000329 ***
## age          0.51182    0.04323  11.840 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 10.59 on 7438 degrees of freedom
## Multiple R-squared:  0.0185, Adjusted R-squared:  0.01837
## F-statistic: 140.2 on 1 and 7438 DF, p-value: < 2.2e-16
```

Боб является 26-летним работником. Предскажите зарплату Боба, используя оцененную регрессию. Алексис является 30-летним работником. Предскажите зарплату Алексис, используя оцененную регрессию.

Создадим «новые» данные для Боба и Алексис.

R

```
new_data <- data.frame(age = c(26, 30))
```

И получим подобранные значения для этих новых данных. Обратите внимание, что нам не нужно создавать **все** переменные исходного датасета; нам достаточно сгенерировать только те переменные, что используются в модели.

R

```
predict(model, new_data)
```

```
##      1      2
## 17.93330 19.98056
```

Python

В python мы **должны** импортировать все что нам нужно до начала работы. Импортируем модули для загрузки данных и оценивания моделей.

Python

```
import numpy as np
import pandas as pd
import statsmodels.api as sm

np.set_printoptions(legacy="1.21")
```

Прочитаем наши данные из Excel в Pandas.

Python

```
dataset = pd.read_excel("data/cps12.xlsx")
dataset.head()
```

```
##   year      ahe bachelor  female  age
## 0  2012  19.230770         0        0  30
## 1  2012  17.548077         0        0  29
## 2  2012   8.547009         0        0  27
## 3  2012  16.826923         0        1  25
## 4  2012  16.346153         1        1  27
```

Оценим регрессию средней почасовой зарплаты (*AHE*) на возраст (*Age*).

Python

```
model = sm.OLS.from_formula("ahe ~ age", data=dataset)
model_est = model.fit()
print(model_est.summary())
```

```
##                               OLS Regression Results
## =====
## Dep. Variable:                ahe    R-squared:                0.018
## Model:                      OLS    Adj. R-squared:           0.018
## Method:                    Least Squares    F-statistic:            140.2
## Date:                      Ср, 02 июл 2025    Prob (F-statistic):      4.72e-32
## Time:                      21:40:16    Log-Likelihood:          -28112.
## No. Observations:           7440    AIC:                     5.623e+04
## Df Residuals:               7438    BIC:                     5.624e+04
## Df Model:                   1
## Covariance Type:            nonrobust
## =====
##               coef    std err          t      P>|t|      [0.025    0.975]
## -----
## Intercept      4.6260      1.288       3.593     0.000       2.102     7.150
## age            0.5118      0.043      11.840     0.000       0.427     0.597
## =====
## Omnibus:                1953.812    Durbin-Watson:           1.853
## Prob(Omnibus):           0.000    Jarque-Bera (JB):        5216.736
## Skew:                   1.406    Prob(JB):                0.00
## Kurtosis:               5.987    Cond. No.                 313.
## =====
##
## Notes:
## [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
```

Боб является 26-летним работником. Предскажите зарплату Боба, используя оцененную регрессию. Алексис является 30-летним работником. Предскажите зарплату Алексис, используя оцененную регрессию.

Создадим «новые» данные для Боба и Алексис.

Python

```
df_new = pd.DataFrame({"age": [26, 30]})
```

И получим подобранные значения для этих новых данных. Обратите внимание, что нам не нужно создавать **все** переменные исходного датасета; нам достаточно сгенерировать только те переменные, что используются в модели.

Python

```
model_est.predict(df_new)
```

```
## 0    17.933295
```

```
## 1    19.980564
```

```
## dtype: float64
```


Тема 5 Тестирование гипотез в модели парной линейной регрессии

Практическое упражнение №1

(СУ, E5.1) Используя базу данных **CPS12**, описанную в упражнении E4.1, оцените регрессию средней почасовой заработной платы (*AHE*) от возраста (*Age*) и выполните следующие упражнения.

- а. Является ли рассчитанный коэффициент наклона регрессии статистически значимым? То есть, можете ли вы отвергнуть нулевую гипотезу $H_0 : \beta_1 = 0$ против двусторонней альтернативной гипотезы на 10%, 5%, или на 1%-м уровнях значимости? Каково p -значение, соответствующее t -статистике коэффициента наклона?
- б. Постройте 95%-й доверительный интервал для коэффициента наклона.
- в. Повторите (а), используя данные только для выпускников средней школы.
- г. Повторите (а), используя данные только для выпускников колледжей.
- д. Различно ли влияние возраста на доход для выпускников средних школ и для выпускников колледжей? Объясните¹.

R

Загрузим данные.

R

```
dataset <- readxl::read_excel("data/cps12.xlsx")
head(dataset)
```

¹Подсказка: см. упражнение (СУ, 5.15).

```
## # A tibble: 6 x 5
##   year   ahe bachelor female age
##   <dbl> <dbl>   <dbl>   <dbl> <dbl>
## 1  2012 19.2         0       0    30
## 2  2012 17.5         0       0    29
## 3  2012  8.55        0       0    27
## 4  2012 16.8         0       1    25
## 5  2012 16.3         1       1    27
## 6  2012 16.1         1       0    30
```

Оценим регрессию средней почасовой заработной платы (*AHE*) от возраста (*Age*).

R

```
model <- lm(ahe ~ age, data = dataset)
```

Ответы на первый вопрос, в большинстве своем, можно получить из сводной таблицы результатов.

R

```
summary(model)
```

```
##
## Call:
## lm(formula = ahe ~ age, data = dataset)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -19.864  -7.381  -2.245   4.799  72.499
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  4.62605    1.28752   3.593 0.000329 ***
## age          0.51182    0.04323  11.840 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 10.59 on 7438 degrees of freedom
## Multiple R-squared:  0.0185, Adjusted R-squared:  0.01837
## F-statistic: 140.2 on 1 and 7438 DF, p-value: < 2.2e-16
```

Нулевую гипотезу $H_0 : \beta_1 = 0$ можно проверить и вручную.

Отдельного t -теста для оцененных коэффициентов найдено не было, значения выше рассчитываются функцией `summary`. Но мы можем, забегаая вперед, воспользоваться F -тестом. t -статистика равна квадратному корню из полученной F -статистики.

R

```
car::linearHypothesis(model, c("age = 0"))
```

```
##
## Linear hypothesis test:
## age = 0
##
## Model 1: restricted model
## Model 2: ahe ~ age
##
##   Res.Df    RSS Df Sum of Sq    F    Pr(>F)
## 1   7439 849515
## 2   7438 833801   1    15714 140.18 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Разумеется, можно рассчитать t -статистику вручную.

R

```
mod_sum <- summary(model)$coefficients
(mod_sum["age", 1] - 0) / mod_sum["age", 2]
```

```
## [1] 11.83955
```

Повторим то же для выпускников средней школы...

R

```
data_b0 <- dataset[dataset$bachelor == 0, ]
model_b0 <- lm(ahe ~ age, data = data_b0)
summary(model_b0)
```

```
##
## Call:
## lm(formula = ahe ~ age, data = data_b0)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -14.333  -5.425  -1.488   3.222  76.409
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  4.31392    1.44025   2.995  0.00276 **
## age          0.38333    0.04832   7.932 2.87e-15 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 8.175 on 3483 degrees of freedom
## Multiple R-squared:  0.01774,    Adjusted R-squared:  0.01746
## F-statistic: 62.92 on 1 and 3483 DF,  p-value: 2.874e-15
```

...и для выпускников колледжей.

R

```
data_b1 <- dataset[dataset$bachelor == 1, ]
model_b1 <- lm(ahe ~ age, data = data_b1)
summary(model_b1)
```

```
##
## Call:
## lm(formula = ahe ~ age, data = data_b1)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -24.077  -7.644  -2.158   5.340  53.260
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  4.33416    1.86834   2.32  0.0204 *
## age          0.64430    0.06277  10.27 <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 11.12 on 3953 degrees of freedom
## Multiple R-squared:  0.02596,    Adjusted R-squared:  0.02572
## F-statistic: 105.4 on 1 and 3953 DF,  p-value: < 2.2e-16
```

Различно ли влияние возраста на доход для выпускников средних школ и для выпускников колледжей? Обратите внимание на альтернативную форму вызова функции `linearHypothesis`.

R

```
test_val <- coef(model_b0)["age"]
car::linearHypothesis(model_b1, c("age"), c(test_val))
```

```
##
## Linear hypothesis test:
## age = 0.383326798869054
##
## Model 1: restricted model
## Model 2: ahe ~ age
##
##   Res.Df    RSS Df Sum of Sq    F    Pr(>F)
## 1    3954 490668
## 2    3953 488532  1    2136.3 17.286 3.283e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Python

Python

```
import numpy as np
import pandas as pd
import statsmodels.api as sm

np.set_printoptions(legacy="1.21")
```

Загрузим данные.

Python

```
df = pd.read_excel("data/cps12.xlsx")
df.head()
```

##	year	ahe	bachelor	female	age
## 0	2012	19.230770	0	0	30
## 1	2012	17.548077	0	0	29
## 2	2012	8.547009	0	0	27
## 3	2012	16.826923	0	1	25
## 4	2012	16.346153	1	1	27

Оценим регрессию средней почасовой заработной платы (*AHE*) от возраста (*Age*).

Python

```
model_est = sm.OLS.from_formula("ahe ~ age", data=df).fit()
```

Ответы на первый вопрос, в большинстве своем, можно получить из сводной таблицы результатов.

Python

```
print(model_est.summary())
```

```
##                                OLS Regression Results
## =====
## Dep. Variable:                ahe    R-squared:                0.018
## Model:                      OLS    Adj. R-squared:           0.018
## Method:                    Least Squares    F-statistic:            140.2
## Date:                      Ср, 02 июл 2025    Prob (F-statistic):      4.72e-32
## Time:                      21:40:19    Log-Likelihood:          -28112.
## No. Observations:          7440    AIC:                    5.623e+04
## Df Residuals:              7438    BIC:                    5.624e+04
## Df Model:                  1
## Covariance Type:            nonrobust
## =====
##               coef    std err          t      P>|t|      [0.025    0.975]
## -----
## Intercept      4.6260      1.288      3.593      0.000      2.102      7.150
## age            0.5118      0.043     11.840      0.000      0.427      0.597
## =====
## Omnibus:                1953.812    Durbin-Watson:           1.853
## Prob(Omnibus):           0.000    Jarque-Bera (JB):        5216.736
## Skew:                   1.406    Prob(JB):                0.00
## Kurtosis:               5.987    Cond. No.:               313.
## =====
##
## Notes:
## [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
```

Нулевую гипотезу $H_0 : \beta_1 = 0$ можно проверить и вручную.

Python

```
model_est.t_test("age = 0")
```

```
## <class 'statsmodels.stats.contrast.ContrastResults'>
##                                Test for Constraints
## =====
##               coef    std err          t      P>|t|      [0.025    0.975]
## -----
## c0            0.5118      0.043     11.840      0.000      0.427      0.597
## =====
```

Повторим то же для выпускников средней школы...

Python

```
df0 = df.loc[df.bachelor == 0, :]
model0_est = sm.OLS.from_formula("ahe ~ age", data=df0).fit()
print(model0_est.summary())
```

```
##                               OLS Regression Results
## =====
## Dep. Variable:                ahe    R-squared:                0.018
## Model:                      OLS    Adj. R-squared:           0.017
## Method:                    Least Squares    F-statistic:           62.92
## Date:                      Ср, 02 июл 2025    Prob (F-statistic):       2.87e-15
## Time:                      21:40:19    Log-Likelihood:          -12266.
## No. Observations:           3485    AIC:                    2.454e+04
## Df Residuals:               3483    BIC:                    2.455e+04
## Df Model:                   1
## Covariance Type:            nonrobust
## =====
##               coef    std err          t      P>|t|      [0.025    0.975]
## -----
## Intercept      4.3139      1.440      2.995      0.003      1.490      7.138
## age            0.3833      0.048      7.932      0.000      0.289      0.478
## =====
## Omnibus:                1427.537    Durbin-Watson:           1.962
## Prob(Omnibus):           0.000    Jarque-Bera (JB):        8226.881
## Skew:                   1.866    Prob(JB):                0.00
## Kurtosis:               9.537    Cond. No.                310.
## =====
##
## Notes:
## [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
```

...и для выпускников колледжей.

Python

```
df1 = df.loc[df.bachelor == 1, :]
model1_est = sm.OLS.from_formula("ahe ~ age", data=df1).fit()
print(model1_est.summary())
```

```

##                                OLS Regression Results
## =====
## Dep. Variable:                ahe    R-squared:                0.026
## Model:                      OLS    Adj. R-squared:           0.026
## Method:                    Least Squares    F-statistic:             105.4
## Date:                      Ср, 02 июл 2025    Prob (F-statistic):       2.05e-24
## Time:                      21:40:19    Log-Likelihood:           -15136.
## No. Observations:           3955    AIC:                     3.028e+04
## Df Residuals:               3953    BIC:                     3.029e+04
## Df Model:                   1
## Covariance Type:            nonrobust
## =====
##               coef    std err          t      P>|t|      [0.025     0.975]
## -----
## Intercept      4.3342      1.868      2.320      0.020      0.671      7.997
## age            0.6443      0.063     10.265      0.000      0.521      0.767
## =====
## Omnibus:                800.725    Durbin-Watson:           1.894
## Prob(Omnibus):           0.000    Jarque-Bera (JB):        1669.563
## Skew:                   1.184    Prob(JB):                0.00
## Kurtosis:               5.127    Cond. No.:               315.
## =====
##
## Notes:
## [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

```

Различно ли влияние возраста на доход для выпускников средних школ и для выпускников колледжей?

Python

```

coef0 = model0_est.params["age"]
model1_est.t_test(f"age = {coef0}")

```

```

## <class 'statsmodels.stats.contrast.ContrastResults'>
##
##                                Test for Constraints
## =====
##               coef    std err          t      P>|t|      [0.025     0.975]
## -----
## c0            0.6443      0.063      4.158      0.000      0.521      0.767
## =====

```

Практическое упражнение №2

(СУ, Е5.3) Используя базу данных **CollegeDistance**, описанную в упражнении Е4.3, оцените регрессию лет полного образования (ED) от расстояния до ближайшего колледжа ($Dist$) и выполните следующие упражнения:

- Является ли рассчитанный коэффициент наклона регрессии статистически значимым? То есть, можете ли вы отвергнуть нулевую гипотезу $H_0 : \beta_1 = 0$ против двусторонней альтернативной гипотезы на 10%, 5%, или на 1%-м уровнях значимости? Каково p -значение, соответствующее t -статистике коэффициента наклона?
- Постройте 95%-й доверительный интервал для коэффициента наклона.
- Оцените регрессию с использованием данных только для женщин и повторите (b).
- Оцените регрессию с использованием данных только для мужчин и повторите (b).
- Различно ли влияние расстояния до колледжа на количество лет, потраченных на образование, для мужчин и для женщин?

R

R

```
dataset <- readxl::read_excel("data/CollegeDistance.xls")
head(dataset)
```

```
## # A tibble: 6 x 14
##   female black hispanic bytest dadcoll momcoll ownhome urban cue80 stwmfg80
##   <dbl> <dbl>   <dbl>   <dbl>   <dbl>   <dbl>   <dbl> <dbl> <dbl>   <dbl>
## 1     0     0       0  39.2     1     0       1     1  6.2    8.09
## 2     1     0       0  48.9     0     0       1     1  6.2    8.09
## 3     0     0       0  48.7     0     0       1     1  6.2    8.09
## 4     0     1       0  40.4     0     0       1     1  6.2    8.09
## 5     1     0       0  40.5     0     0       0     1  5.6    8.09
## 6     0     0       0  54.7     0     0       1     1  5.6    8.09
## # i 4 more variables: dist <dbl>, tuition <dbl>, ed <dbl>, incomehi <dbl>
```

Оценим регрессию лет полного образования (ED) от расстояния до ближайшего колледжа ($Dist$).

R

```
model <- lm(ed ~ dist, data = dataset)
summary(model)
```

```
##
## Call:
## lm(formula = ed ~ dist, data = dataset)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.9559 -1.8091 -0.6624  2.0515  4.4844
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 13.95586    0.03772 369.945  <2e-16 ***
## dist        -0.07337    0.01375  -5.336   1e-07 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.807 on 3794 degrees of freedom
## Multiple R-squared:  0.00745,    Adjusted R-squared:  0.007188
## F-statistic: 28.48 on 1 and 3794 DF,  p-value: 1.004e-07
```

Оценим регрессию только для женщин.

R

```
data_f <- dataset[dataset$female == 1, ]
model_f <- lm(ed ~ dist, data = data_f)
summary(model_f)
```

```
##
## Call:
## lm(formula = ed ~ dist, data = data_f)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.9359 -1.8075 -0.6632  2.0706  4.4491
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  13.93587    0.05112  272.593 < 2e-16 ***
## dist         -0.06417    0.01881   -3.412 0.000657 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.802 on 2068 degrees of freedom
## Multiple R-squared:  0.005599,    Adjusted R-squared:  0.005118
## F-statistic: 11.64 on 1 and 2068 DF,  p-value: 0.0006567
```

Оценим регрессию только для мужчин.

R

```
data_m <- dataset[dataset$female == 0, ]
model_m <- lm(ed ~ dist, data = data_m)
summary(model_m)
```

```
##
## Call:
## lm(formula = ed ~ dist, data = data_m)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.9790 -1.8113 -0.6856  2.0294  4.3983
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  13.97899    0.05593  249.939 < 2e-16 ***
## dist         -0.08384    0.02017   -4.157 3.38e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.814 on 1724 degrees of freedom
## Multiple R-squared:  0.009925,    Adjusted R-squared:  0.009351
## F-statistic: 17.28 on 1 and 1724 DF,  p-value: 3.38e-05
```

Различно ли влияние расстояния до колледжа на количество лет, потраченных на образование, для мужчин и для женщин?

R

```
coef_f <- coef(model_f)["dist"]
car::linearHypothesis(model_m, c("dist"), c(coef_f))
```

```
##
## Linear hypothesis test:
## dist = - 0.0641675674705812
##
## Model 1: restricted model
## Model 2: ed ~ dist
##
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1    1725 5677.5
## 2    1724 5674.4   1     3.1311 0.9513 0.3295
```

Python

Python

```
import numpy as np
import pandas as pd
import statsmodels.api as sm

np.set_printoptions(legacy="1.21")
```

Загрузим данные.

Python

```
df = pd.read_excel("data/CollegeDistance.xls")
df.head()
```

```
##   female  black  hispanic  bytest  ...  dist  tuition  ed  incomehi
## 0      0      0         0   39.15  ...   0.2   0.88915  12         1
## 1      1      0         0   48.87  ...   0.2   0.88915  12         0
## 2      0      0         0   48.74  ...   0.2   0.88915  12         0
## 3      0      1         0   40.40  ...   0.2   0.88915  12         0
## 4      1      0         0   40.48  ...   0.4   0.88915  13         0
##
## [5 rows x 14 columns]
```

Оценим регрессию лет полного образования (*ED*) от расстояния до ближайшего колледжа (*Dist*).

Python

```
model = sm.OLS.from_formula("ed ~ dist", data=df).fit()
print(model.summary())
```

```
##                               OLS Regression Results
## =====
## Dep. Variable:                ed    R-squared:                0.007
## Model:                      OLS    Adj. R-squared:           0.007
## Method:                    Least Squares    F-statistic:           28.48
## Date:                      Ср, 02 июл 2025    Prob (F-statistic):      1.00e-07
## Time:                      21:40:21    Log-Likelihood:          -7632.2
## No. Observations:           3796    AIC:                    1.527e+04
## Df Residuals:               3794    BIC:                    1.528e+04
## Df Model:                   1
## Covariance Type:            nonrobust
## =====
##               coef    std err          t      P>|t|      [0.025    0.975]
## -----
## Intercept      13.9559      0.038    369.945      0.000     13.882     14.030
## dist           -0.0734      0.014    -5.336      0.000     -0.100     -0.046
## =====
## Omnibus:                7187.794    Durbin-Watson:           1.769
## Prob(Omnibus):           0.000    Jarque-Bera (JB):        361.676
## Skew:                   0.410    Prob(JB):                2.90e-79
## Kurtosis:               1.729    Cond. No.                 3.73
## =====
##
## Notes:
## [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
```

Оценим регрессию только для женщин.

Python

```
df_f = df.loc[df.female == 1, :]
model_f = sm.OLS.from_formula("ed ~ dist", data=df_f).fit()
print(model_f.summary())
```

```
##                                OLS Regression Results
## =====
## Dep. Variable:                ed    R-squared:                0.006
## Model:                      OLS    Adj. R-squared:           0.005
## Method:                    Least Squares    F-statistic:           11.64
## Date:                      Ср, 02 июл 2025    Prob (F-statistic):     0.000657
## Time:                      21:40:21    Log-Likelihood:         -4155.7
## No. Observations:          2070    AIC:                    8315.
## Df Residuals:              2068    BIC:                    8327.
## Df Model:                  1
## Covariance Type:            nonrobust
## =====
##               coef    std err          t      P>|t|      [0.025    0.975]
## -----
## Intercept    13.9359     0.051    272.593     0.000     13.836     14.036
## dist         -0.0642     0.019    -3.412     0.001     -0.101     -0.027
## =====
## Omnibus:                4409.472    Durbin-Watson:           1.836
## Prob(Omnibus):           0.000    Jarque-Bera (JB):        197.938
## Skew:                   0.402    Prob(JB):                1.04e-43
## Kurtosis:               1.716    Cond. No.:               3.71
## =====
##
## Notes:
## [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
```

Оценим регрессию только для мужчин.

Python

```
df_m = df.loc[df.female == 0, :]
model_m = sm.OLS.from_formula("ed ~ dist", data=df_m).fit()
print(model_m.summary())
```

```
##                                OLS Regression Results
## =====
## Dep. Variable:                ed    R-squared:                0.010
## Model:                      OLS    Adj. R-squared:           0.009
## Method:                    Least Squares    F-statistic:            17.28
## Date:                      Ср, 02 июл 2025    Prob (F-statistic):      3.38e-05
## Time:                      21:40:22    Log-Likelihood:          -3476.2
## No. Observations:           1726    AIC:                     6956.
## Df Residuals:               1724    BIC:                     6967.
## Df Model:                   1
## Covariance Type:            nonrobust
## =====
##                coef    std err          t      P>|t|      [0.025    0.975]
## -----
## Intercept      13.9790      0.056    249.939      0.000     13.869     14.089
## dist           -0.0838      0.020     -4.157      0.000     -0.123     -0.044
## =====
## Omnibus:                2413.485    Durbin-Watson:           1.689
## Prob(Omnibus):           0.000    Jarque-Bera (JB):        163.988
## Skew:                   0.419    Prob(JB):                2.46e-36
## Kurtosis:               1.744    Cond. No.                 3.75
## =====
##
## Notes:
## [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
```

Различно ли влияние расстояния до колледжа на количество лет, потраченных на образование, для мужчин и для женщин?

Python

```
coef_f = model_f.params["dist"]
model_m.t_test(f"dist = {coef_f}")
```

```
## <class 'statsmodels.stats.contrast.ContrastResults'>
##
##                                Test for Constraints
## =====
##                coef    std err          t      P>|t|      [0.025    0.975]
## -----
## c0           -0.0838      0.020     -0.975      0.330     -0.123     -0.044
## =====
```

Тема 6 Гетероскедастичность

Практическое упражнение

(СУ, Е5.1) Используя базу данных **CPS12**, описанную в упражнении **Е4.1**, оцените регрессию средней почасовой заработной платы *AHE* от возраста *Age* и выполните следующие упражнения:

- Графический анализ гетероскедастичности (квадраты и остатков и графики их зависимости).
- Тестирование гетероскедастичности (тесты Глейзера, Голдфелда-Квандта и ВМНК).
- Ошибки Уайта.

Повторите упражнение отдельно для групп женщин и мужчин; групп с высшим образованием и без него.

R

Загрузим данные.

R

```
library(ggplot2)

dataset <- readxl::read_excel("data/cps12.xlsx")
head(dataset)
```

```
## # A tibble: 6 x 5
##   year  ahe bachelor female  age
##   <dbl> <dbl>   <dbl>   <dbl> <dbl>
## 1  2012 19.2     0     0    30
## 2  2012 17.5     0     0    29
## 3  2012  8.55    0     0    27
## 4  2012 16.8     0     1    25
## 5  2012 16.3     1     1    27
## 6  2012 16.1     1     0    30
```

Оценим регрессию средней почасовой заработной платы (*AHE*) от возраста (*Age*).

R


```
model <- lm(ahe ~ age, data = dataset)
```

Графический анализ гетероскедастичности

Построим график квадратов остатков. Это можно сделать при помощи функции `plot` или `ggplot`.


R

```
plot(seq_along(model$residuals), model$residuals^2)
```



R


```
ggplot(dataset, aes(x = seq_along(model$residuals))) +  
  geom_point(aes(y = model$residuals^2))
```

Графики относительно *Age* и *Ahe*.


R

```
ggplot(dataset, aes(x = age)) +  
  geom_point(aes(y = model$residuals^2))
```



R

```
ggplot(dataset, aes(x = ahe)) +  
  geom_point(aes(y = model$residuals^2))
```



Проведем тест Голдфельда-Квандта.

R

```
lmtest::gqtest(model, order.by = ~ age, data = dataset, fraction = .3)
```

```
##
## Goldfeld-Quandt test
##
## data: model
## GQ = 1.3678, df1 = 2602, df2 = 2602, p-value = 7.912e-16
## alternative hypothesis: variance increases from segment 1 to 2
```

Проведем тест Бройша-Пагана.

R

```
lmtest::bptest(model, ~ age, data = dataset, studentize = TRUE)
```

```
##
## studentized Breusch-Pagan test
##
## data: model
## BP = 27.354, df = 1, p-value = 1.694e-07
```

Проведем тест Уайта.

R

```
lmtest::bptest(model, ~ age + I(age^2), data = dataset, studentize = TRUE)
```

```
##
## studentized Breusch-Pagan test
##
## data: model
## BP = 27.471, df = 2, p-value = 1.083e-06
```

Проведем тест Глейзера.

R

```
skedastic::glejser(model)
```

```
## # A tibble: 1 x 4
##   statistic p.value parameter alternative
##   <dbl>    <dbl>    <dbl> <chr>
## 1      91.2 1.32e-21         1 greater
```

Взвешенный МНК и устойчивые оценки дисперсии Уайта

Так как тесты на гетероскедастичность показали ее наличие, имеет смысл воспользоваться взвешенным МНК.

Предположим, что дисперсия пропорциональна возрасту. Тогда нужно каждое наблюдение пронормировать на $\frac{1}{\sqrt{Ahe_i}}$.

R

```
wmodel <- lm(I(ahe / sqrt(age)) ~ -1 + I(1 / sqrt(age)) + sqrt(age), data = dataset)
summary(wmodel)
```

```
##
## Call:
## lm(formula = I(ahe/sqrt(age)) ~ -1 + I(1/sqrt(age)) + sqrt(age),
##     data = dataset)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.4109 -1.3421 -0.4011  0.8719 13.7028
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## I(1/sqrt(age))  4.45786    1.26461   3.525 0.000426 ***
## sqrt(age)       0.51749    0.04285  12.076 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.941 on 7438 degrees of freedom
## Multiple R-squared:  0.7784, Adjusted R-squared:  0.7784
## F-statistic: 1.307e+04 on 2 and 7438 DF,  p-value: < 2.2e-16
```

Функция `lm()` в R может принимать необязательный аргумент `weights`, задающий веса для наблюдений. Причем в R минимизируется $\sum_{i=1}^n w_i \hat{u}_i^2$, то есть в `weights` в нашем случае нужно передавать $\frac{1}{Age_i}$.

R

```
wmodel <- lm(ahe ~ age, data = dataset, weights = 1 / dataset$age)
summary(wmodel)
```

```
##
## Call:
## lm(formula = ahe ~ age, data = dataset, weights = 1/dataset$age)
##
## Weighted Residuals:
##      Min       1Q   Median       3Q      Max
## -3.4109 -1.3421 -0.4011  0.8719 13.7028
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  4.45786    1.26461   3.525 0.000426 ***
## age          0.51749    0.04285  12.076 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.941 on 7438 degrees of freedom
## Multiple R-squared:  0.01923,    Adjusted R-squared:  0.0191
## F-statistic: 145.8 on 1 and 7438 DF,  p-value: < 2.2e-16
```

Сегодня ВМНК применяется редко. Исследователи отдают предпочтение устойчивым к гетероскедастичности стандартным ошибкам Уайта.

R

```
model <- lm(ahe ~ age, data = dataset)
hcCOV <- sandwich::vcovHC(model, type = "HC3")
sqrt(diag(hcCOV))
```

```
## (Intercept)      age
##   1.2706546   0.0432225
```

R: дополнительные тесты

Данные тесты на выявление автокорреляции следует применять в случае рассмотрения временных рядов. Для межобъектных данных они малоосмысленны. Сейчас мы просто рассмотрим способы их применения, игнорируя данное замечание!

Проведем тест Дарбина-Уотсона.

R

```
lmtest::dwtest(model)
```

```
##  
## Durbin-Watson test  
##  
## data: model  
## DW = 1.8528, p-value = 1.081e-10  
## alternative hypothesis: true autocorrelation is greater than 0
```

Проведем тест Бройша-Годфри.

R

```
lmtest::bptest(formula(model), order = 3, data = dataset)
```

```
##  
## Breusch-Godfrey test for serial correlation of order up to 3  
##  
## data: formula(model)  
## LM test = 81.224, df = 3, p-value < 2.2e-16
```

Проведем тест Харке-Бера на нормальность распределения остатков.

R

```
tseries::jarque.bera.test(model$residuals)
```

```
##  
## Jarque Bera Test  
##  
## data: model$residuals  
## X-squared = 5216.7, df = 2, p-value < 2.2e-16
```

Проведем тест Чоу на стабильность оценок модели.

R

```
strucchange::sctest(formula(model), type = "Chow", point = 1500, data = dataset)
```

```
##  
## Chow test  
##  
## data: formula(model)  
## F = 3.3757, p-value = 0.03425
```

Python

Импортируем пакеты.

Python

```
import numpy as np
import pandas as pd
import statsmodels.api as sm
import statsmodels.stats.api as sms
import matplotlib.pyplot as plt
import seaborn as sb

from scipy.stats import chi2

np.set_printoptions(legacy="1.21")
```

Загрузим данные.

Python

```
df = pd.read_excel("data/cps12.xlsx")
```

Оценим регрессию средней почасовой заработной платы (*AHE*) от возраста (*Age*).

Python


```
model = sm.OLS.from_formula("ahe ~ age", data=df)
model_est = model.fit()
```

Графический анализ гетероскедастичности

Построим диаграмму рассеяния квадрата остатков при помощи matplotlib.

Python


```
plt.clf()
plt.scatter(range(len(model_est.resid)), model_est.resid ** 2)
plt.show()
```



И при помощи seaborn.

Python


```
plt.clf()
sb.scatterplot(x = range(len(model_est.resid)), y = model_est.resid ** 2)
plt.show()
```



Графики относительно *Age* и *Ahe*.


Python

```
plt.clf()
sb.scatterplot(df, x = "age", y = model_est.resid ** 2)
plt.show()
```



Python

```
plt.clf()
sb.scatterplot(df, x = "ahe", y = model_est.resid ** 2)
plt.show()
```



Проведем тест Голдфелда-Квандта.

Python

```
sms.het_goldfeldquandt(y=model.endog, x=model.exog, idx = 1, split=.35, drop=.3)
```

```
## (1.3559833310942084, 4.5493616238697035e-15, 'increasing')
```

Проведем тест Бройша-Пагана.

Python

```
sms.het_breuschpagan(model_est.resid, model.exog)
```

```
## (27.354094082360767, 1.69405398802106e-07, 27.447655583031647, 1.6583420766689666e-07)
```

Проведем тест Уайта.

Python

```
sms.het_white(model_est.resid, model.exog)
```

```
## (27.47100506683621, 1.083295760596925e-06, 13.780847590728703, 1.0619810952820436e-06)
```

Проведем тест Глейзера. В python авторы не смогли обнаружить рабо-

тающей реализации теста. Посчитаем все вручную. Сначала импортируем функцию из `scipy`, нужную для нахождения критических значений распределения χ^2 , а затем рассчитаем тестовую статистику.

После оценивания модели и получения модуля остатков $|\hat{u}|$ оценивается вспомогательная модель

$$|\hat{u}| = \beta_0 + Z\beta + v$$

где Z — объясняющие переменные вспомогательного уравнения. Часто в качестве Z берут переменные исходной модели. Тест имеет две статистики:

$$nR^2 \sim \chi^2(k)$$

$$\frac{ESS_{aux}}{\left(1 - \frac{2}{\pi}\right) \hat{\sigma}^2} \sim \chi^2(k)$$

где ESS_{aux} — объясненная сумма квадратов вспомогательной модели, $\hat{\sigma}^2$ — выборочная дисперсия остатков исходной или вспомогательной модели [Mittelhammer, Judge, Miller, 2000].

Python

```
model_aux = sm.OLS.from_formula("abs(model_est.resid) ~ age", data=df)
model_aux_est = model_aux.fit()
stat_aux = model_aux_est.ess / ((1 - 2 / np.pi) * np.var(model_est.resid))
print(f"Stat: {stat_aux:5.4f}, Critical value: {chi2.ppf(0.95,
↪ df=model_aux.df_model):5.4f}, p-value: {1 - chi2.cdf(stat_aux,
↪ df=model_aux.df_model):5.4f}")
```

```
## Stat: 91.1745, Critical value: 3.8415, p-value: 0.0000
```

Взвешенный МНК и устойчивые оценки дисперсии Уайта

Так как тесты на гетероскедастичность показали ее наличие, имеет смысл воспользоваться взвешенным МНК.

Предположим, что дисперсия пропорциональна возрасту. Тогда нужно каждое наблюдение пронормировать на $\frac{1}{\sqrt{Age_i}}$.

Python

```
from numpy import sqrt

wmodel = sm.OLS.from_formula("I(ahe / sqrt(age)) ~ -1 + I(1 / sqrt(age)) +
    ↪ sqrt(age)", data=dataset)
wmodel_est = wmodel.fit()
print(wmodel_est.summary())
```

```
##                               OLS Regression Results
## =====
## Dep. Variable:      I(ahe / sqrt(age))  R-squared (uncentered):      0.778
## Model:              OLS  Adj. R-squared (uncentered):      0.778
## Method:             Least Squares  F-statistic:              1.307e+04
## Date:               Cp, 02 июл 2025  Prob (F-statistic):      0.00
## Time:               21:40:41  Log-Likelihood:           -15489.
## No. Observations:   7440  AIC:                      3.098e+04
## Df Residuals:       7438  BIC:                      3.100e+04
## Df Model:           2
## Covariance Type:    nonrobust
## =====
##                               coef      std err          t      P>|t|      [0.025      0.975]
## -----
## I(1 / sqrt(age))    4.4579      1.265       3.525     0.000     1.979     6.937
## sqrt(age)           0.5175      0.043     12.076     0.000     0.433     0.601
## =====
## Omnibus:            1993.798  Durbin-Watson:           1.852
## Prob(Omnibus):      0.000  Jarque-Bera (JB):        5475.553
## Skew:               1.423  Prob(JB):                 0.00
## Kurtosis:           6.093  Cond. No.                 306.
## =====
##
## Notes:
## [1] R² is computed without centering (uncentered) since the model does not contain a constant.
## [2] Standard Errors assume that the covariance matrix of the errors is correctly specified.
```

Функция `lm()` в R может принимать необязательный аргумент `weights`, задающий веса для наблюдений. Причем в R минимизируется $\sum_{i=1}^n w_i \hat{u}_i^2$, то есть в `weights` в нашем случае нужно передавать $\frac{1}{Age_i}$.

Python

```
wmodel = smf.wls("ahe ~ age", data=dataset, weights=(1 / dataset.age))
wmodel_est = wmodel.fit()
print(wmodel_est.summary())
```

```

##                               WLS Regression Results
## =====
## Dep. Variable:                ahe    R-squared:                0.019
## Model:                      WLS    Adj. R-squared:           0.019
## Method:                    Least Squares    F-statistic:            145.8
## Date:                      Ср, 02 июл 2025    Prob (F-statistic):      2.90e-33
## Time:                      21:40:41    Log-Likelihood:          -28081.
## No. Observations:          7440    AIC:                    5.617e+04
## Df Residuals:              7438    BIC:                    5.618e+04
## Df Model:                  1
## Covariance Type:            nonrobust
## =====
##               coef      std err          t      P>|t|      [0.025      0.975]
## -----
## Intercept      4.4579      1.265       3.525     0.000       1.979       6.937
## age            0.5175      0.043     12.076     0.000       0.433       0.601
## =====
## Omnibus:                1993.798    Durbin-Watson:           1.852
## Prob(Omnibus):           0.000    Jarque-Bera (JB):        5475.553
## Skew:                   1.423    Prob(JB):                0.00
## Kurtosis:               6.093    Cond. No.:               306.
## =====
##
## Notes:
## [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

```

Сегодня ВМНК применяется редко. Исследователи отдают предпочтение устойчивым к гетероскедастичности стандартным ошибкам Уайта. В python устойчивые ошибки можно посчитать двумя способами (это, на самом деле, один способ, но слегка по-разному реализуемый).

Python

```

model = sm.OLS.from_formula("ahe ~ age", data=dataset)
model_est = model.fit()
print(model_est.get_robustcov_results(cov_type="HC3").summary())

```

```
##                               OLS Regression Results
## =====
## Dep. Variable:                ahe    R-squared:                0.018
## Model:                      OLS    Adj. R-squared:           0.018
## Method:                    Least Squares    F-statistic:            140.2
## Date:                      Ср, 02 июл 2025    Prob (F-statistic):      4.62e-32
## Time:                      21:40:41    Log-Likelihood:          -28112.
## No. Observations:           7440    AIC:                     5.623e+04
## Df Residuals:                7438    BIC:                     5.624e+04
## Df Model:                    1
## Covariance Type:            HC3
## =====
##               coef    std err          t      P>|t|      [0.025    0.975]
## -----
## Intercept      4.6260      1.271      3.641      0.000      2.135      7.117
## age            0.5118      0.043     11.841      0.000      0.427      0.597
## =====
## Omnibus:                1953.812    Durbin-Watson:           1.853
## Prob(Omnibus):          0.000    Jarque-Bera (JB):        5216.736
## Skew:                   1.406    Prob(JB):                 0.00
## Kurtosis:               5.987    Cond. No.                 313.
## =====
##
## Notes:
## [1] Standard Errors are heteroscedasticity robust (HC3)
```

Python

```
model = sm.OLS.from_formula("ahe ~ age", data=dataset)
model_est = model.fit(cov_type='HC3')
print(model_est.summary())
```

```

##                                OLS Regression Results
## =====
## Dep. Variable:                ahe    R-squared:                0.018
## Model:                      OLS    Adj. R-squared:           0.018
## Method:                    Least Squares    F-statistic:             140.2
## Date:                      Ср, 02 июл 2025    Prob (F-statistic):       4.62e-32
## Time:                      21:40:42    Log-Likelihood:           -28112.
## No. Observations:           7440    AIC:                     5.623e+04
## Df Residuals:               7438    BIC:                     5.624e+04
## Df Model:                   1
## Covariance Type:            HC3
## =====
##               coef      std err          z      P>|z|      [0.025      0.975]
## -----
## Intercept      4.6260      1.271       3.641     0.000       2.136       7.116
## age            0.5118      0.043     11.841     0.000       0.427       0.597
## =====
## Omnibus:                1953.812    Durbin-Watson:           1.853
## Prob(Omnibus):           0.000    Jarque-Bera (JB):        5216.736
## Skew:                   1.406    Prob(JB):                0.00
## Kurtosis:               5.987    Cond. No.:               313.
## =====
##
## Notes:
## [1] Standard Errors are heteroscedasticity robust (HC3)

```

Python: дополнительные тесты

Данные тесты на выявление автокорреляции следует применять в случае рассмотрения временных рядов. Для межобъектных данных они малоосмысленны. Сейчас мы просто рассмотрим способы их применения, игнорируя данное замечание!

Проведем тест Дарбина-Уотсона.

Python

```
sms.durbin_watson(model_est.resid)
```

```
## 1.852819187401235
```

Проведем тест Бройша-Годфри.

Python

```
sms.acorr_breusch_godfrey(model_est, nlags=3)
```

```
## (81.2243910735383, 1.6764179760766054e-17, 27.355245841858235, 1.377718242092972e-17)
```

Проведем тест Харке-Бера на нормальность распределения остатков.

Python

```
sms.jarque_bera(model_est.resid)
```

```
## (5216.736149641615, 0.0, 1.4061065110013002, 5.986576475959586)
```

Проведем тест Чоу на стабильность оценок модели.

Python

```
from chow_test import chow_test  
chow_test(y_series=pd.Series(model.endog), X_series=pd.DataFrame(model.exog),  
          ↪ last_index=1499, first_index=1500, significance=0.05)
```

```
## Fail to reject the null hypothesis of equality of regression coefficients in the two periods.  
## Chow Statistic: 2.2587400010167853, P_value: 0.07947530812960613  
## (2.2587400010167853, 0.07947530812960613)
```


Тема 8 Модель множественной линейной регрессии

Практическое упражнение

(СУ, E6.2) Используя базу данных **CollegeDistance**, описанную в компьютерном упражнении [Сток, Уотсон, 2015, E4.3], выполните следующие задания.

- а. Оцените регрессию числа полных лет обучения (ED) от расстояния до ближайшего колледжа ($Dist$). Чему равен оцененный коэффициент наклона?
- б. Оцените регрессию ED на $Dist$, включив дополнительные переменные для контроля за характеристиками студентов и их семей, а также местного рынка труда. В частности, включите в качестве дополнительных регрессоров переменные *Bytest*, *Female*, *Black*, *Hispanic*, *Incomehi*, *Ownhome*, *DadColl*, *Cue80* и *Stwmfg80*. Каково оцененное влияние $Dist$ на ED ?
- в. Отличается ли существенно предполагаемое влияние $Dist$ на ED в регрессии из пункта (б) от предполагаемого влияния $Dist$ на ED в регрессии из пункта (а)? Основываясь на этом выводе, что вы можете сказать о наличии смещения из-за пропущенной переменной оценок регрессии из пункта (а)?
- г. Сравните качество приближения данных регрессиями из пунктов (а) и (б), используя стандартную ошибку регрессии, коэффициент детерминации R^2 и скорректированный коэффициент детерминации $\bar{R}^2$. Почему R^2 и $\bar{R}^2$ так близки в регрессии (б)?
- д. Значение коэффициента при переменной *DadColl* положительно. Что показывает этот коэффициент?
- е. Объясните, почему переменные *Cue80* и *Stwmfg80* появились в регрессии. Считаете ли вы, что знаки оцененных коэффициентов (+ или –) при этих переменных отражают реальную действительность? Дайте интерпретацию величине этих коэффициентов.

- ж. Боб — чернокожий мужчина. Средняя школа, в которой он учился, располагалась в 20 милях от ближайшего колледжа. Его сводная выпускная оценка (*Bytest*) составила 58 баллов. Доход его семьи в 1980 году составил \$26000 и семья владела домом. Его мама посещала колледж, а отец — нет. Уровень безработицы в округе составлял 7,5%, а средняя почасовая заработная плата — \$9,75. Рассчитайте предсказанное моделью число полных лет обучения Боба с использованием регрессии из пункта (б).
- з. Джим имеет те же характеристики, что и Боб, за исключением того, что его школа располагалась в 40 милях от ближайшего колледжа. Рассчитайте предсказанное моделью число полных лет обучения Джима с использованием регрессии из пункта (б).

R

Загрузим данные и оценим регрессию числа полных лет обучения (*ED*) от расстояния до ближайшего колледжа (*Dist*).

R

```
dataset <- readxl::read_excel("data/CollegeDistance.xls")
model0 <- lm(ed ~ dist, data = dataset)
summary(model0)
```

```
##
## Call:
## lm(formula = ed ~ dist, data = dataset)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.9559 -1.8091 -0.6624  2.0515  4.4844
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  13.95586    0.03772  369.945  <2e-16 ***
## dist         -0.07337    0.01375  -5.336   1e-07 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.807 on 3794 degrees of freedom
## Multiple R-squared:  0.00745,    Adjusted R-squared:  0.007188
## F-statistic: 28.48 on 1 and 3794 DF,  p-value: 1.004e-07
```

Оценим регрессию, включив в нее дополнительные переменные: *Bytest*, *Female*, *Black*, *Hispanic*, *Incomehi*, *Ownhome*, *DadColl*, *Cue80* и *Stwmfg80*.

R

```
model1 <- lm(ed ~ dist + bytest + female + black + hispanic + incomehi + ownhome +
  ↪ dadcoll + cue80 + stwmfg80, data = dataset)
summary(model1)
```

```
##
## Call:
## lm(formula = ed ~ dist + bytest + female + black + hispanic +
##     incomehi + ownhome + dadcoll + cue80 + stwmfg80, data = dataset)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -4.0906 -1.1419 -0.2288  1.1670  5.2712
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  8.827518   0.250278  35.271 < 2e-16 ***
## dist         -0.031539   0.012370  -2.550  0.01083 *
## bytest        0.093820   0.003162  29.669 < 2e-16 ***
## female        0.145408   0.050589   2.874  0.00407 **
## black         0.367971   0.071363   5.156 2.65e-07 ***
## hispanic      0.398520   0.074462   5.352 9.21e-08 ***
## incomehi      0.395198   0.060531   6.529 7.51e-11 ***
## ownhome       0.152131   0.066807   2.277  0.02283 *
## dadcoll       0.696132   0.068725  10.129 < 2e-16 ***
## cue80         0.023205   0.009632   2.409  0.01604 *
## stwmfg80     -0.051778   0.019852  -2.608  0.00914 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.542 on 3785 degrees of freedom
## Multiple R-squared:  0.2788, Adjusted R-squared:  0.2769
## F-statistic: 146.3 on 10 and 3785 DF, p-value: < 2.2e-16
```

Отличается ли существенно предполагаемое влияние *Dist* на *ED* в регрессии из пункта (b) от предполагаемого влияния *Dist* на *ED* в регрессии из пункта (a)?

R

```
coef0 <- coef(model0)["dist"]
car::linearHypothesis(model1, c("dist"), c(coef0))
```

```
##
## Linear hypothesis test:
## dist = - 0.0733727071292028
##
## Model 1: restricted model
## Model 2: ed ~ dist + bytest + female + black + hispanic + incomehi + ownhome +
##      dadcoll + cue80 + stwmfg80
##
##   Res.Df    RSS Df Sum of Sq    F    Pr(>F)
## 1   3786 9032.6
## 2   3785 9005.4  1    27.21 11.437 0.0007274 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Боб — чернокожий мужчина. Средняя школа, в которой он учился, располагалась в 20 милях от ближайшего колледжа. Его сводная выпускная оценка (*Bytest*) составила 58 баллов. Доход его семьи в 1980 году составил \$26000 и семья владела домом. Его мама посещала колледж, а отец — нет. Уровень безработицы в округе составлял 7,5%, а средняя почасовая заработная плата — \$9,75. Рассчитайте предсказанное моделью число полных лет обучения Боба с использованием регрессии из пункта (b).

Создадим данные для Боба.

R

```
data_bob <- data.frame(
  black = 1,
  female = 0,
  hispanic = 0,
  dist = 20,
  bytest = 58,
  incomehi = 1,
  ownhome = 1,
  dadcoll = 0,
  cue80 = 0.075,
  stwmfg80 = 9.75
)
```

И подберем значения для новых данных.

R

```
predict(model1, data_bob)
```

```
##      1  
## 14.05052
```

Джим имеет те же характеристики, что и Боб, за исключением того, что его школа располагалась в 40 милях от ближайшего колледжа. Рассчитайте предсказанное моделью число полных лет обучения Джима с использованием регрессии из пункта (b).

Вместо того, чтобы вручную создавать данные для Джима, просто скопирем и подправим данные для Боба.

R

```
data_jim <- data_bob  
data_jim$dist <- 40
```

И подберем значения для новых данных.

R

```
predict(model1, data_jim)
```

```
##      1  
## 13.41974
```

Тестирование мультиколлинеарности

Рассмотрим дополнительно тест VIF на наличие мультиколлинеарности.

R

```
car::vif(model1)
```

```
##      dist  bytest  female    black hispanic incomehi ownhome dadcoll
## 1.111361 1.240549 1.012409 1.263365 1.127228 1.194612 1.054314 1.214947
##      cue80 stwmfg80
## 1.215333 1.170263
```

Посмотрим на пример совершенной мультиколлинеарности.

R

```
model11 <- lm(ed ~ dist + bytest + I(1 - female) + female + black + hispanic +
  ↪ incomehi + ownhome + dadcoll + cue80 + stwmfg80, data = dataset)
summary(model11)
```

```
##
## Call:
## lm(formula = ed ~ dist + bytest + I(1 - female) + female + black +
##      hispanic + incomehi + ownhome + dadcoll + cue80 + stwmfg80,
##      data = dataset)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -4.0906 -1.1419 -0.2288  1.1670  5.2712
##
## Coefficients: (1 not defined because of singularities)
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   8.972926   0.246575  36.390 < 2e-16 ***
## dist         -0.031539   0.012370  -2.550  0.01083 *
## bytest         0.093820   0.003162  29.669 < 2e-16 ***
## I(1 - female) -0.145408   0.050589  -2.874  0.00407 **
## female                NA             NA      NA      NA
## black          0.367971   0.071363   5.156 2.65e-07 ***
## hispanic       0.398520   0.074462   5.352 9.21e-08 ***
## incomehi       0.395198   0.060531   6.529 7.51e-11 ***
## ownhome        0.152131   0.066807   2.277 0.02283 *
## dadcoll        0.696132   0.068725  10.129 < 2e-16 ***
## cue80          0.023205   0.009632   2.409 0.01604 *
## stwmfg80      -0.051778   0.019852  -2.608 0.00914 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.542 on 3785 degrees of freedom
## Multiple R-squared:  0.2788, Adjusted R-squared:  0.2769
## F-statistic: 146.3 on 10 and 3785 DF, p-value: < 2.2e-16
```

Python

Python

```
import numpy as np
import pandas as pd
import statsmodels.api as sm

np.set_printoptions(legacy="1.21")
```

Загрузим данные и оценим регрессию числа полных лет обучения (*ED*) от расстояния до ближайшего колледжа (*Dist*).

Python

```
df = pd.read_excel("data/CollegeDistance.xls")

model0 = sm.OLS.from_formula("ed ~ dist", data=df)
model0_est = model0.fit()
print(model0_est.summary())
```

```
##                               OLS Regression Results
## =====
## Dep. Variable:                ed    R-squared:                0.007
## Model:                      OLS    Adj. R-squared:           0.007
## Method:                    Least Squares    F-statistic:           28.48
## Date:                      Ср, 02 июл 2025    Prob (F-statistic):     1.00e-07
## Time:                      21:40:46    Log-Likelihood:         -7632.2
## No. Observations:           3796    AIC:                    1.527e+04
## Df Residuals:                3794    BIC:                    1.528e+04
## Df Model:                    1
## Covariance Type:            nonrobust
## =====
##               coef    std err          t      P>|t|      [0.025    0.975]
## -----
## Intercept      13.9559      0.038     369.945      0.000      13.882      14.030
## dist           -0.0734      0.014     -5.336      0.000      -0.100      -0.046
## =====
## Omnibus:                7187.794    Durbin-Watson:           1.769
## Prob(Omnibus):           0.000    Jarque-Bera (JB):        361.676
## Skew:                   0.410    Prob(JB):                 2.90e-79
## Kurtosis:               1.729    Cond. No.                 3.73
## =====
##
## Notes:
## [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
```

Оценим регрессию, включив в нее дополнительные переменные: *Bytest*, *Female*, *Black*, *Hispanic*, *Incomehi*, *Ownhome*, *DadColl*, *Cue80* и *Stwmfg80*.

Python

```
model1 = sm.OLS.from_formula("ed ~ dist + bytest + female + black + hispanic +
    ↪ incomehi + ownhome + dadcoll + cue80 + stwmfg80", data=df)
model1_est = model1.fit()
print(model1_est.summary())
```



```

##                                OLS Regression Results
## =====
## Dep. Variable:                  ed    R-squared:                  0.279
## Model:                        OLS    Adj. R-squared:             0.277
## Method:                      Least Squares    F-statistic:              146.3
## Date:                        Ср, 02 июл 2025    Prob (F-statistic):       6.94e-260
## Time:                        21:40:46    Log-Likelihood:           -7025.9
## No. Observations:             3796    AIC:                      1.407e+04
## Df Residuals:                 3785    BIC:                      1.414e+04
## Df Model:                     10
## Covariance Type:              nonrobust
## =====
##               coef    std err          t      P>|t|      [0.025     0.975]
## -----
## Intercept      8.8275      0.250     35.271     0.000      8.337      9.318
## dist          -0.0315      0.012     -2.550     0.011     -0.056     -0.007
## bytest         0.0938      0.003     29.669     0.000      0.088      0.100
## female         0.1454      0.051      2.874     0.004      0.046      0.245
## black          0.3680      0.071      5.156     0.000      0.228      0.508
## hispanic       0.3985      0.074      5.352     0.000      0.253      0.545
## incomehi       0.3952      0.061      6.529     0.000      0.277      0.514
## ownhome        0.1521      0.067      2.277     0.023      0.021      0.283
## dadcoll        0.6961      0.069     10.129     0.000      0.561      0.831
## cue80          0.0232      0.010      2.409     0.016      0.004      0.042
## stwmfg80       -0.0518      0.020     -2.608     0.009     -0.091     -0.013
## =====
## Omnibus:                  118.266    Durbin-Watson:              1.924
## Prob(Omnibus):              0.000    Jarque-Bera (JB):           97.867
## Skew:                       0.320    Prob(JB):                   5.60e-22
## Kurtosis:                   2.543    Cond. No.:                   539.
## =====
##
## Notes:
## [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

```

Отличается ли существенно предполагаемое влияние *Dist* на *ED* в регрессии из пункта (b) от предполагаемого влияния *Dist* на *ED* в регрессии из пункта (a)?

Python

```

coef0 = model0_est.params["dist"]
model1_est.t_test(f"dist = {coef0}")

```

```
## <class 'statsmodels.stats.contrast.ContrastResults'>
##
##              Test for Constraints
## =====
##      coef    std err          t      P>|t|    [0.025    0.975]
## -----
## c0      -0.0315     0.012     3.382     0.001    -0.056    -0.007
## =====
```

Боб — чернокожий мужчина... Создадим данные для Боба.

Python

```
df_bob = pd.DataFrame({
    "black": 1,
    "female": 0,
    "hispanic": 0,
    "dist": 20,
    "bystest": 58,
    "incomehi": 1,
    "ownhome": 1,
    "dadcoll": 0,
    "cue80": 0.075,
    "stwmfg80": 9.75
}, index=[0])
```

И подберем значения для новых данных.

Python

```
model1_est.predict(df_bob)
```

```
## 0    14.050519
## dtype: float64
```

Джим имеет те же характеристики, что и Боб...

Python

```
df_jim = df_bob.copy()
df_jim.loc[0, "dist"] = 40
```

И подберем значения для новых данных.

Python

```
model1_est.predict(df_jim)
```

```
## 0      13.419744  
## dtype: float64
```

Тестирование мультиколлинеарности

Рассмотрим дополнительно тест VIF на наличие мультиколлинеарности. В python есть функция, вычисляющая значение VIF для одной переменной, которую можно найти в пакете statsmodels. На вход она принимает матрицу X (можно взять из **неоцененной** модели) и номер столбца, содержащего интересующую переменную.

Python

```
from statsmodels.stats.outliers_influence import variance_inflation_factor as vif  
  
for i in range(1, model1.exog.shape[1]):  
    vif_est = vif(model1.exog, i)  
    print(f"{model1_est.params.index[i]:8}: {vif_est:5.4f}")
```

```
## dist      : 1.1114  
## bytest    : 1.2405  
## female    : 1.0124  
## black     : 1.2634  
## hispanic  : 1.1272  
## incomehi  : 1.1946  
## ownhome   : 1.0543  
## dadcoll   : 1.2149  
## cue80     : 1.2153  
## stwmfg80  : 1.1703
```

Посмотрим на пример совершенной мультиколлинеарности.

Python

```
model1 = sm.OLS.from_formula("ed ~ dist + bytest + I(1 - female) + female + black +  
↪ hispanic + incomehi + ownhome + dadcoll + cue80 + stwmfg80", data=df)  
model1.fit().summary()
```

```

## <class 'statsmodels.iolib.summary.Summary'>
## """
##
##                               OLS Regression Results
## =====
## Dep. Variable:                ed    R-squared:                0.279
## Model:                        OLS    Adj. R-squared:           0.277
## Method:                       Least Squares    F-statistic:             146.3
## Date:                          Ср, 02 июл 2025    Prob (F-statistic):       6.94e-260
## Time:                           21:40:48    Log-Likelihood:           -7025.9
## No. Observations:              3796    AIC:                      1.407e+04
## Df Residuals:                  3785    BIC:                      1.414e+04
## Df Model:                       10
## Covariance Type:               nonrobust
## =====
##
##                coef    std err          t      P>|t|      [0.025     0.975]
## -----
## Intercept         5.9335      0.165     36.012     0.000      5.610      6.257
## dist              -0.0315      0.012    -2.550     0.011     -0.056     -0.007
## bytest            0.0938      0.003    29.669     0.000      0.088      0.100
## I(1 - female)     2.8940      0.088    32.910     0.000      2.722      3.066
## female            3.0394      0.084    36.021     0.000      2.874      3.205
## black             0.3680      0.071      5.156     0.000      0.228      0.508
## hispanic          0.3985      0.074      5.352     0.000      0.253      0.545
## incomehi          0.3952      0.061      6.529     0.000      0.277      0.514
## ownhome           0.1521      0.067      2.277     0.023      0.021      0.283
## dadcoll           0.6961      0.069    10.129     0.000      0.561      0.831
## cue80             0.0232      0.010      2.409     0.016      0.004      0.042
## stwmfg80          -0.0518      0.020     -2.608     0.009     -0.091     -0.013
## =====
## Omnibus:                118.266    Durbin-Watson:           1.924
## Prob(Omnibus):           0.000    Jarque-Bera (JB):         97.867
## Skew:                    0.320    Prob(JB):                 5.60e-22
## Kurtosis:                2.543    Cond. No.                 2.43e+16
## =====
##
## Notes:
## [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
## [2] The smallest eigenvalue is 1.82e-26. This might indicate that there are
## strong multicollinearity problems or that the design matrix is singular.
## """

```

Обратите внимание на то, что, на первый взгляд, все нормально. Однако 2-я сноска под таблицей говорит нам о том, что что-то в модели не так. Посмотрим на более явный пример.

Python

```
model2 = sm.OLS.from_formula("ed ~ I(1 - female) + female", data=df)
model2.fit().summary()
```

```
## <class 'statsmodels.iolib.summary.Summary'>
## """
##
##                      OLS Regression Results
## =====
## Dep. Variable:          ed    R-squared:                -0.035
## Model:                  OLS    Adj. R-squared:            -0.036
## Method:                 Least Squares    F-statistic:            -64.51
## Date:                   Cp, 02 июл 2025    Prob (F-statistic):      1.00
## Time:                   21:40:48    Log-Likelihood:         -7712.1
## No. Observations:       3796    AIC:                    1.543e+04
## Df Residuals:           3793    BIC:                    1.545e+04
## Df Model:                2
## Covariance Type:        nonrobust
## =====
##               coef    std err          t      P>|t|      [0.025    0.975]
## -----
## Intercept          2.216e+12    4.74e+12     0.468    0.640    -7.07e+12    1.15e+13
## I(1 - female)     -2.216e+12    4.74e+12    -0.468    0.640    -1.15e+13    7.07e+12
## female            -2.216e+12    4.74e+12    -0.468    0.640    -1.15e+13    7.07e+12
## =====
## Omnibus:              4076.875    Durbin-Watson:           1.744
## Prob(Omnibus):         0.000    Jarque-Bera (JB):        333.882
## Skew:                  0.392    Prob(JB):                 3.15e-73
## Kurtosis:              1.777    Cond. No.:                3.36e+14
## =====
##
## Notes:
## [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
## [2] The smallest eigenvalue is 5.06e-26. This might indicate that there are
## strong multicollinearity problems or that the design matrix is singular.
## """
```


Тема 9 Выбор спецификации модели: контрольные переменные

Практическое упражнение №1

(СУ, E7.1) Используя базу данных **CPS12**, описанную в **E4.1**, ответьте на следующие вопросы:

- а. Оцените регрессию средней зарплаты в час (AHE) на возраст (Age). Чему равна оценка свободного члена? Чему равна оценка коэффициента наклона?
- б. Оцените регрессию AHE на Age , пол ($Female$) и образование ($Bachelor$). Чему равна оценка влияния переменной Age на доход? Постройте 95%-й доверительный интервал для коэффициента перед Age в регрессии.
- в. Существенны ли различия в оценках влияния переменной Age на AHE в регрессиях из пунктов (а) и (б)? Можно ли сказать, что оценка соответствующего коэффициента в регрессии из пункта (а) смещена из-за пропущенных переменных?
- г. Боб — 26-летний мужчина, имеющий школьный аттестат. Рассчитайте доход Боба, используя оценённую в пункте (б) регрессию. Алексис — 30-летняя женщина с дипломом бакалавра. Рассчитайте доход Алексис, используя ту же самую регрессию.
- д. Используя стандартные ошибки регрессии, R^2 и $\bar{R}^2$, сравните, насколько хорошо регрессии из пунктов (а) и (б) объясняют данные. Почему R^2 и $\bar{R}^2$ так близки между собой в регрессии из пункта (б)?
- е. Являются ли пол и образование факторами, определяющими доход? Проверьте нулевую гипотезу о том, что переменная $Female$ может быть исключена из регрессии. Проверьте нулевую гипотезу о том, что переменная $Bachelor$ может быть исключена из регрессии. Проверьте нулевую гипотезу о том, что обе переменные $Female$ и $Bachelor$ могут быть исключены из регрессии.
- ж. Оценка регрессии будет смещена из-за пропущенных переменных, ес-

ли выполняются два условия. Какие это условия? Можно ли сказать, что эти условия выполняются здесь?

R

Загрузим данные.

R

```
library(ggplot2)

dataset <- readxl::read_excel("data/cps12.xlsx")
head(dataset)
```

```
## # A tibble: 6 x 5
##   year   ahe bachelor female  age
##   <dbl> <dbl>   <dbl>   <dbl> <dbl>
## 1  2012 19.2         0       0    30
## 2  2012 17.5         0       0    29
## 3  2012  8.55        0       0    27
## 4  2012 16.8         0       1    25
## 5  2012 16.3         1       1    27
## 6  2012 16.1         1       0    30
```

Оценим регрессию средней почасовой заработной платы (*AHE*) от возраста (*Age*).

R

```
model0 <- lm(ahe ~ age, data = dataset)
summary(model0)
```



```
##
## Call:
## lm(formula = ahe ~ age, data = dataset)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -19.864  -7.381  -2.245   4.799  72.499
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  4.62605     1.28752   3.593 0.000329 ***
## age          0.51182     0.04323  11.840 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 10.59 on 7438 degrees of freedom
## Multiple R-squared:  0.0185, Adjusted R-squared:  0.01837
## F-statistic: 140.2 on 1 and 7438 DF, p-value: < 2.2e-16
```

Оценим регрессию *AHE* на *Age*, пол (*Female*) и образование (*Bachelor*).

R

```
model1 <- lm(ahe ~ age + female + bachelor, data = dataset)
summary(model1)
```

```
##
## Call:
## lm(formula = ahe ~ age + female + bachelor, data = dataset)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -23.688  -6.207  -1.708   4.280  75.302
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  1.86620     1.18760   1.571   0.116
## age          0.51029     0.03952  12.912 <2e-16 ***
## female      -3.81030     0.22960 -16.596 <2e-16 ***
## bachelor     8.31863     0.22739  36.584 <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 9.678 on 7436 degrees of freedom
## Multiple R-squared:  0.1801, Adjusted R-squared:  0.1798
## F-statistic: 544.5 on 3 and 7436 DF, p-value: < 2.2e-16
```

Существенны ли различия в оценках влияния переменной *Age* на *AHE* в регрессиях из пунктов (а) и (b)?

R

```
coef0 <- coef(model0)["age"]
car::linearHypothesis(model1, c("age"), c(coef0))
```

```
##
## Linear hypothesis test:
## age = 0.511817132277454
##
## Model 1: restricted model
## Model 2: ahe ~ age + female + bachelor
##
##   Res.Df    RSS Df Sum of Sq   F Pr(>F)
## 1    7437 696511
## 2    7436 696511   1    0.1406 0.0015 0.9691
```

Боб — 26-летний мужчина, имеющий школьный аттестат. Алексис — 30-летняя женщина с дипломом бакалавра.

Построим новый датафрейм с данными Боба и Алексис, после чего получим подобранные значения.

R

```
data_new <- data.frame(age = c(26, 30), female = c(0, 1), bachelor = c(0, 1))
predict(model1, data_new)
```

```
##      1      2
## 15.13363 21.68310
```

Являются ли пол и образование факторами, определяющими доход? Гипотезы для **отдельных** переменных можно проверить при помощи статистик, приведенных в результатах оценивания либо при помощи `linearHypothesis`. Совместную гипотезу получится проверить только при помощи `linearHypothesis`.

R

```
car::linearHypothesis(model1, c("female", "bachelor"))
```

```
##
## Linear hypothesis test:
## female = 0
## bachelor = 0
##
## Model 1: restricted model
## Model 2: ahe ~ age + female + bachelor
##
##   Res.Df    RSS Df Sum of Sq    F    Pr(>F)
## 1    7438 833801
## 2    7436 696511  2    137291 732.86 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Обратите внимание, что если все ограничения сравнивают коэффициенты с нулем, то писать `linearHypothesis(model1, c("female", "bachelor"), c(0, 0))` не обязательно. Тот же результат, кстати, можно получить и следующим образом.

R

```
car::linearHypothesis(model1, c("female = 0", "bachelor = 0"))
```

```
##
## Linear hypothesis test:
## female = 0
## bachelor = 0
##
## Model 1: restricted model
## Model 2: ahe ~ age + female + bachelor
##
##   Res.Df    RSS Df Sum of Sq    F    Pr(>F)
## 1    7438 833801
## 2    7436 696511  2    137291 732.86 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Python

Python

```
import numpy as np
import pandas as pd
import statsmodels.api as sm

np.set_printoptions(legacy="1.21")
```

Загрузим данные.

Python

```
df = pd.read_excel("data/cps12.xlsx")
```

Оценим регрессию средней почасовой заработной платы (*AHE*) от возраста (*Age*).

Python

```
model0 = sm.OLS.from_formula("ahe ~ age", data=df).fit()
print(model0.summary())
```

```
##                                OLS Regression Results
## =====
## Dep. Variable:                ahe    R-squared:                0.018
## Model:                      OLS    Adj. R-squared:           0.018
## Method:                    Least Squares    F-statistic:             140.2
## Date:                      Ср, 02 июл 2025    Prob (F-statistic):       4.72e-32
## Time:                      21:40:50    Log-Likelihood:           -28112.
## No. Observations:           7440    AIC:                     5.623e+04
## Df Residuals:               7438    BIC:                     5.624e+04
## Df Model:                   1
## Covariance Type:            nonrobust
## =====
##               coef      std err          t      P>|t|      [0.025      0.975]
## -----
## Intercept      4.6260      1.288       3.593     0.000       2.102       7.150
## age            0.5118      0.043     11.840     0.000       0.427       0.597
## =====
## Omnibus:                1953.812    Durbin-Watson:           1.853
## Prob(Omnibus):           0.000    Jarque-Bera (JB):         5216.736
## Skew:                   1.406    Prob(JB):                 0.00
## Kurtosis:               5.987    Cond. No.:                313.
## =====
##
## Notes:
## [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
```

Оценим регрессию *AHE* на *Age*, пол (*Female*) и образование (*Bachelor*).

Python

```
model1 = sm.OLS.from_formula("ahe ~ age + female + bachelor", data=df).fit()
print(model1.summary())
```

```
##                                OLS Regression Results
## =====
## Dep. Variable:                 ahe    R-squared:                 0.180
## Model:                       OLS    Adj. R-squared:            0.180
## Method:                     Least Squares    F-statistic:              544.5
## Date:                       Ср, 02 июл 2025    Prob (F-statistic):       6.51e-320
## Time:                       21:40:50    Log-Likelihood:           -27443.
## No. Observations:            7440    AIC:                      5.489e+04
## Df Residuals:                7436    BIC:                      5.492e+04
## Df Model:                    3
## Covariance Type:            nonrobust
## =====
##               coef    std err          t      P>|t|      [0.025    0.975]
## -----
## Intercept      1.8662      1.188       1.571     0.116     -0.462     4.194
## age            0.5103      0.040      12.912     0.000      0.433     0.588
## female        -3.8103      0.230     -16.596     0.000     -4.260    -3.360
## bachelor       8.3186      0.227      36.584     0.000      7.873     8.764
## =====
## Omnibus:                 1975.582    Durbin-Watson:            1.935
## Prob(Omnibus):           0.000    Jarque-Bera (JB):        6089.399
## Skew:                   1.360    Prob(JB):                 0.00
## Kurtosis:                6.499    Cond. No.                 316.
## =====
##
## Notes:
## [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
```

Существенны ли различия в оценках влияния переменной *Age* на *AHE* в регрессиях из пунктов (а) и (b)?

Python

```
coef0 = model0.params["age"]
model1.t_test(f"age = {coef0}")
```

```
## <class 'statsmodels.stats.contrast.ContrastResults'>
##                                Test for Constraints
## =====
##               coef    std err          t      P>|t|      [0.025    0.975]
## -----
## c0            0.5103      0.040     -0.039     0.969      0.433     0.588
## =====
```

Боб — 26-летний мужчина, имеющий школьный аттестат... Алексис — 30-летняя женщина с дипломом бакалавра...

Построим новый датафрейм с данными Боба и Алексис, после чего получим подобранные значения.

Python

```
df_new = pd.DataFrame({
    "age": [26, 30],
    "female": [0, 1],
    "bachelor": [0, 1]
})

model1.predict(df_new)
```

```
## 0    15.133633
## 1    21.683100
## dtype: float64
```

Являются ли пол и образование факторами, определяющими доход? Гипотезы для **отдельных** переменных можно проверить при помощи статистик, приведенных в результатах оценивания либо при помощи `t_test`. Совместную гипотезу будем тестировать при помощи `f_test`.

В python метод `f_test` для **оцененной** модели принимает на вход один из трех вариантов входных параметров:

- Матрицу размера $p \times k$, где p — число индивидуальных ограничений, k — число объясняющих переменных. Ненулевые элементы матрицы показывают, с каким коэффициентом соответствующая переменная входит в соответствующее ограничение. В данном случае подразумевается равенство нулю во всех ограничениях.
- Кортеж из матрицы, аналогичной таковой в предыдущем пункте, и вектор-столбца размера p , в котором указано, равенство какому числу рассматривается в соответствующем ограничении.
- Строку с явной записью ограничений через запятую.

Python

```
model1.f_test("female = 0, bachelor = 0")
```

```
## <class 'statsmodels.stats.contrast.ContrastResults'>  
## <F test: F=732.862334510276, p=3.1253721294361518e-291, df_denom=7.44e+03, df_num=2>
```

Рассмотрим тот же тест, проведенный при помощи матрицы с ограничениями.

Python

```
R = np.zeros((2, 4))  
R[0, 2] = 1  
R[1, 3] = 1  
model1.f_test(R)
```

```
## <class 'statsmodels.stats.contrast.ContrastResults'>  
## <F test: F=732.862334510276, p=3.1253721294361518e-291, df_denom=7.44e+03, df_num=2>
```

Результат тот же, удобства меньше. Хотя для каких-то автоматизированных расчетов самое оно.

Практическое упражнение №2

(СУ, Е7.3) Используя базу данных **CollegeDistance**, описанную Е4.3, ответьте на следующие вопросы:

- а. Одна организация, выступающая с пропагандой образования, утверждает, что, в среднем, уровень образования человека повысится примерно на 0.15 года, если расстояние до ближайшего высшего учебного заведения снизится на 20 миль. Оцените регрессию числа полных лет обучения (*ED*) на расстояние до ближайшего колледжа (*Dist*). Согласуются ли результаты оценки регрессии с тем, что утверждает эта организация? Поясните.
- б. Есть и другие факторы, которые влияют число полных лет обучения. Изменится ли оценка влияния расстояния до ближайшего колледжа на число полных лет обучения, если контролировать на эти другие факторы? Для ответа на данный вопрос, постройте таблицу, подобную табли-

це 7.1. Включите в неё простую спецификацию (построенную в пункте (а)), базовую спецификацию (которая включает набор важных контрольных переменных) и несколько модификаций базовой спецификации. Обсудите различия в оценках коэффициента при *Dist* на *ED* между этими спецификациями.

- в. Некоторые исследователи считают, что, если контролировать на другие факторы, то число полных лет обучения чёрнокожих и испаноязычных граждан будет больше, чем белых. Согласуется ли этот результат с регрессиями, которые вы построили в пункте (b)?

R

Загрузим данные и оценим регрессию числа полных лет обучения (*ED*) от расстояния до ближайшего колледжа (*Dist*).

R

```
dataset <- readxl::read_excel("data/CollegeDistance.xls")
model0 <- lm(ed ~ dist, data = dataset)
summary(model0)
```

```
##
## Call:
## lm(formula = ed ~ dist, data = dataset)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.9559 -1.8091 -0.6624  2.0515  4.4844
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  13.95586    0.03772  369.945  <2e-16 ***
## dist         -0.07337    0.01375  -5.336   1e-07 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.807 on 3794 degrees of freedom
## Multiple R-squared:  0.00745,    Adjusted R-squared:  0.007188
## F-statistic: 28.48 on 1 and 3794 DF,  p-value: 1.004e-07
```

Построим дополнительные модели с добавленными контрольными переменными:

- добавим фиктивные переменные пола и национальности.

R

```
model1 <- lm(ed ~ dist + female + black + hispanic, data = dataset)
```

- добавим фиктивные переменные образования родителей.

R

```
model2 <- lm(ed ~ dist + female + black + hispanic + momcoll + dadcoll, data =  
↪ dataset)
```

- добавим уровень безработицы.

R

```
model3 <- lm(ed ~ dist + female + black + hispanic + momcoll + dadcoll + cue80, data  
↪ = dataset)
```

- добавим среднюю почасовую зарплату в штате.

R

```
model4 <- lm(ed ~ dist + female + black + hispanic + momcoll + dadcoll + cue80 +  
↪ stwmfg80, data = dataset)
```

Сведем все результаты в одну таблицу. В силу технических ограничений выведем только model0 и model4.

R

```
stargazer::stargazer(model0, model2, model4, type = "text")
```

Dependent variable:			
	ed		
	(1)	(2)	(3)
dist	-0.073*** (0.014)	-0.050*** (0.013)	-0.058*** (0.014)
female		0.043 (0.056)	0.038 (0.056)
black		-0.381*** (0.073)	-0.382*** (0.074)
hispanic		-0.045 (0.080)	-0.061 (0.081)
momcoll		0.666*** (0.090)	0.672*** (0.090)
dadcoll		0.995*** (0.078)	1.001*** (0.079)
cue80			0.022** (0.011)
stwmfg80			-0.011 (0.022)
Constant	13.956*** (0.038)	13.679*** (0.056)	13.630*** (0.211)
Observations	3,796	3,796	3,796
R2	0.007	0.108	0.109
Adjusted R2	0.007	0.107	0.107
Residual Std. Error	1.807 (df = 3794)	1.715 (df = 3789)	1.714 (df = 3787)
F Statistic	28.476*** (df = 1; 3794)	76.466*** (df = 6; 3789)	57.924*** (df = 8; 3787)
Note: *p<0.1; **p<0.05; ***p<0.01			

Python

Python

```
import numpy as np
import pandas as pd
import statsmodels.api as sm

np.set_printoptions(legacy="1.21")
```

Загрузим данные и оценим регрессию числа полных лет обучения (*ED*) от расстояния до ближайшего колледжа (*Dist*).

Python

```
df = pd.read_excel("data/CollegeDistance.xls")

model0 = sm.OLS.from_formula("ed ~ dist", data=df).fit()
```

Построим дополнительные модели с добавленными контрольными переменными:

- добавим фиктивные переменные пола и национальности.

Python

```
model1 = sm.OLS.from_formula("ed ~ dist + female + black + hispanic", data=df).fit()
```

- добавим фиктивные переменные образования родителей.

Python

```
model2 = sm.OLS.from_formula("ed ~ dist + female + black + hispanic + momcoll +  
↪ dadcoll", data=df).fit()
```

- добавим уровень безработицы.

Python

```
model3 = sm.OLS.from_formula("ed ~ dist + female + black + hispanic + momcoll +  
↪ dadcoll + cue80", data=df).fit()
```

- добавим среднюю почасовую зарплату в штате.

Python

```
model4 = sm.OLS.from_formula("ed ~ dist + female + black + hispanic + momcoll +  
↪ dadcoll + cue80 + stwmfg80", data=df).fit()
```

Сведем все результаты в одну таблицу (так как страница не резиновая, выведем только модели 0, 2 и 4). В python есть порт пакета stargazer, но он не умеет выводить таблицы в текстовом виде, только в html и L^AT_EX. Если вы работаете в Jupyter, то достаточно следующей команды:

Python

```
from stargazer.stargazer import Stargazer  
  
Stargazer([model0, model2, model4])
```

```
## <stargazer.stargazer.Stargazer object at 0x000001D80752B7D0>
```

Если же вы работаете в чем-то ином — консоли или R Markdown (в котором данный мануал и написан) — то можно воспользоваться, например, yatg. В силу технических ограничений выведем только model0 и model4.

Python

```
import yatg  
  
print(yatg.html_2_ascii_table(  
    Stargazer([model0, model4]).render_html()  
))
```

##				
##		-----+-----+-----		
##		Dependent variable: ed		
##				
##		(1)		(2)
##				
##		Intercept		13.956***
##				13.630***
##		(0.038)		(0.211)
##		black		-0.382***
##				(0.074)
##		cue80		0.022**
##				(0.011)
##		dadcoll		1.001***
##				(0.079)
##		dist		-0.073***
##				-0.058***
##		(0.014)		(0.014)
##		female		0.038
##				(0.056)
##		hispanic		-0.061
##				(0.081)
##		momcoll		0.672***
##				(0.090)
##		stwmfg80		-0.011
##				(0.022)
##				
##		Observations		3796
##				3796
##		R2		0.007
##				0.109
##		Adjusted R2		0.007
##				0.107
##		Residual Std. Error		1.807 (df=3794)
##				1.714 (df=3787)
##		F Statistic		28.476*** (df=1; 3794)
##				57.924*** (df=8; 3787)
##				
##		Note:		*p<0.1; **p<0.05; ***p<0.01

Практическое упражнение №3

(СУ, Е7.4) Используя базу данных **Growth**, описанную в **Е4.4**, но не включая данные по Мальте (Malta), выполните следующие упражнения:

- Оцените регрессию *Growth* от переменных *TradeShare*, *YearsSchool*, *Rev_Coups*, *Assassinations* и *RGDP60*. Постройте 95%-й доверительный интервал для коэффициента при *TradeShare*. Является ли этот коэффициент статистически значимым на 5%-м уровне значимости?
- Проверьте гипотезу о том, что *YearsSchool*, *Rev_Coups*, *Assassinations*

и *RGDP60* можно одновременно исключить из регрессии. Чему равно p -значение F -статистики?

R

Загрузим данные, отфильтруем их и оценим регрессию *Growth* от переменных *TradeShare*, *YearsSchool*, *Rev_Coups*, *Assassinations* и *RGDP60*.

R

```
dataset <- readxl::read_excel("data/Growth.xlsx")
dataset <- dataset[dataset$country_name != "Malta", ]

model0 <- lm(growth ~ tradeshare + yearsschool + rev_coups + assassinations + rgdp60,
  ↪ data = dataset)
summary(model0)
```

```
##
## Call:
## lm(formula = growth ~ tradeshare + yearsschool + rev_coups +
##   assassinations + rgdp60, data = dataset)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.6897 -0.9459 -0.0565  0.8286  5.1534
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   0.6268915   0.7830280   0.801  0.42663
## tradeshare    1.3408193   0.9600631   1.397  0.16786
## yearsschool    0.5642445   0.1431131   3.943  0.00022 ***
## rev_coups     -2.1504256   1.1185900  -1.922  0.05947 .
## assassinations 0.3225844   0.4880043   0.661  0.51121
## rgdp60        -0.0004613   0.0001508  -3.059  0.00336 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.594 on 58 degrees of freedom
## Multiple R-squared:  0.2911, Adjusted R-squared:  0.23
## F-statistic: 4.764 on 5 and 58 DF, p-value: 0.001028
```

Проверим гипотезу о том, что *YearsSchool*, *Rev_Coups*, *Assassinations* и *RGDP60* можно одновременно исключить из регрессии. Чему равно p -значение F -статистики?

R

```
car::linearHypothesis(model0, c("yearsschool=0", "rev_coups=0", "assassinations=0",
  ↪ "rgdp60=0"))
```

```
##
## Linear hypothesis test:
## yearsschool = 0
## rev_coups = 0
## assassinations = 0
## rgdp60 = 0
##
## Model 1: restricted model
## Model 2: growth ~ tradeshare + yearsschool + rev_coups + assassinations +
##   rgdp60
##
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1      62 198.53
## 2      58 147.31   4    51.217 5.0414 0.001481 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Python

Python

```
import numpy as np
import pandas as pd
import statsmodels.api as sm

np.set_printoptions(legacy="1.21")
```

Загрузим данные, отфильтруем их и оценим регрессию *Growth* от переменных *TradeShare*, *YearsSchool*, *Rev_Coups*, *Assassinations* и *RGDP60*.

Python

```
df = pd.read_excel("data/Growth.xlsx")
```

```
##
↪ C:\Users\zyama\AppData\Local\pypoetry\Cache\VIRTUAL~1\ECONOM~1.12\Lib\site-packages\openpyxl\worksheet\_reader.py:329:
↪ UserWarning: Unknown extension is not supported and will be removed
## warn(msg)
```


Python

```
df = df.loc[df.country_name != "Malta", :]

model = sm.OLS.from_formula("growth ~ tradeshare + yearsschool + rev_coups +
↪ assassinations + rgdp60", data=df).fit()

print(model.summary())
```

```
##                                OLS Regression Results
## =====
## Dep. Variable:                growth    R-squared:                0.291
## Model:                        OLS      Adj. R-squared:           0.230
## Method:                       Least Squares    F-statistic:                4.764
## Date:                         Ср, 02 июл 2025    Prob (F-statistic):         0.00103
## Time:                         21:40:55    Log-Likelihood:             -117.49
## No. Observations:              64    AIC:                        247.0
## Df Residuals:                  58    BIC:                        259.9
## Df Model:                      5
## Covariance Type:              nonrobust
## =====
##                                coef    std err          t      P>|t|      [0.025    0.975]
## -----
## Intercept                    0.6269     0.783     0.801     0.427    -0.941     2.194
## tradeshare                   1.3408     0.960     1.397     0.168    -0.581     3.263
## yearsschool                   0.5642     0.143     3.943     0.000     0.278     0.851
## rev_coups                    -2.1504     1.119    -1.922     0.059    -4.390     0.089
## assassinations                0.3226     0.488     0.661     0.511    -0.654     1.299
## rgdp60                       -0.0005     0.000    -3.059     0.003    -0.001    -0.000
## =====
## Omnibus:                      7.569    Durbin-Watson:              2.130
## Prob(Omnibus):                 0.023    Jarque-Bera (JB):            8.597
## Skew:                         0.494    Prob(JB):                    0.0136
## Kurtosis:                     4.499    Cond. No.                    2.59e+04
## =====
##
## Notes:
## [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
## [2] The condition number is large, 2.59e+04. This might indicate that there are
## strong multicollinearity or other numerical problems.
```

Проверим гипотезу о том, что *YearsSchool*, *Rev_Coups*, *Assassinations* и *RGDP60* можно одновременно исключить из регрессии. Чему равно p -значение F -статистики?

Python

```
model.f_test("yearsschool = 0, rev_coups = 0, assassinations = 0, rgdp60 = 0")
```

```
## <class 'statsmodels.stats.contrast.ContrastResults'>  
## <F test: F=5.041359542406447, p=0.0014806697273907743, df_denom=58, df_num=4>
```

Тема 10 Нелинейные регрессионные модели

Практическое упражнение №1

(СУ, E8.1) Используя базу данных **CPS12**, описанную в **E4.1**, ответьте на следующие вопросы.

- а. Оцените регрессию средней почасовой зарплаты (AHE) на возраст (Age), пол ($Female$) и образование ($Bachelor$). Каково ожидаемое изменение зарплаты, если Age увеличивается с 25 до 26? Каково ожидаемое изменение зарплаты, если Age возрастет с 33 до 34?
- б. Оцените регрессию логарифма средней почасовой зарплаты $\ln(AHE)$ на Age , $Female$ и $Bachelor$. Каково ожидаемое изменение зарплаты, если Age увеличивается с 25 до 26? Каково ожидаемое изменение зарплаты, если Age возрастет с 33 до 34?
- в. Оцените регрессию логарифма средней почасовой зарплаты $\ln(AHE)$ на $\ln(Age)$, $Female$ и $Bachelor$. Каково ожидаемое изменение зарплаты, если Age увеличивается с 25 до 26? Каково ожидаемое изменение зарплаты, если Age возрастет с 33 до 34?
- г. Оцените регрессию логарифма средней почасовой зарплаты $\ln(AHE)$ на Age , Age^2 , $Female$ и $Bachelor$. Каково ожидаемое изменение зарплаты, если Age увеличивается с 25 до 26? Каково ожидаемое изменение зарплаты, если Age возрастет с 33 до 34?
- д. Предпочитаете ли вы регрессию из пункта (в) регрессии из пункта (б)? Объясните.
- е. Предпочитаете ли вы регрессию из пункта (г) регрессии из пункта (б)? Объясните.
- ж. Предпочитаете ли вы регрессию из пункта (г) регрессии из пункта (в)? Объясните.
- з. Начертите график функции регрессии между Age и $\ln(AHE)$ из пунктов (б), (в) и (г) для мужчин, имеющих высшее образование. Объясните сходства и различия между оцененными функциями регрессий. Изме-

нится ли ваш ответ, если вы начертите график функции регрессии для женщин с высшим образованием?

- и. Оцените регрессию $\ln(AHE)$ на Age , Age^2 , $Female$, $Bachelor$ и компоненту взаимодействия $Female \times Bachelor$. Что измеряет коэффициент при компоненте взаимодействия? Алексис является 30-летней женщиной с дипломом бакалавра. Чему равно предсказанное значение $\ln(AHE)$ для Алексис? Джейн является 30-летней женщиной со средним образованием. Чему равно предсказанное значение $\ln(AHE)$ для Джейн? Какова предсказанная разность между зарплатами Алексис и Джейн? Боб является 30-летним мужчиной с дипломом бакалавра. Чему равно предсказанное значение $\ln(AHE)$ для него? Джим является 30-летним мужчиной со средним образованием. Чему равно предсказанное значение $\ln(AHE)$ для Джима? Какова предсказанная разность между зарплатами Боба и Джима?
- к. Различается ли эффект влияния переменной Age на доходы для мужчин и женщин? Специфицируйте и оцените регрессию, которую вы можете использовать для ответа на этот вопрос.
- л. Различается ли эффект влияния переменной Age на доходы для людей имеющих среднее и высшее образование? Специфицируйте и оцените регрессию, которую вы можете использовать для ответа на этот вопрос.
- м. Оценив все эти регрессии (и любые другие, которые вы хотите оценить), сделайте выводы об эффекте влияния возраста на доходы для молодых работников.

R

Загрузим данные.

R

```
library(ggplot2)

dataset <- readxl::read_excel("data/cps12.xlsx")
head(dataset)
```

```
## # A tibble: 6 x 5
##   year  ahe bachelor female  age
##   <dbl> <dbl>   <dbl> <dbl> <dbl>
## 1  2012 19.2       0      0   30
## 2  2012 17.5       0      0   29
## 3  2012  8.55      0      0   27
## 4  2012 16.8       0      1   25
## 5  2012 16.3       1      1   27
## 6  2012 16.1       1      0   30
```

Оценим регрессию средней почасовой зарплаты (*AHE*) на возраст (*Age*), пол (*Female*) и образование (*Bachelor*).

R

```
model0 <- lm(ahe ~ age + female + bachelor, data = dataset)
summary(model0)
```

```
##
## Call:
## lm(formula = ahe ~ age + female + bachelor, data = dataset)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -23.688  -6.207  -1.708   4.280  75.302
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  1.86620    1.18760   1.571   0.116
## age          0.51029    0.03952  12.912 <2e-16 ***
## female      -3.81030    0.22960 -16.596 <2e-16 ***
## bachelor     8.31863    0.22739  36.584 <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 9.678 on 7436 degrees of freedom
## Multiple R-squared:  0.1801, Adjusted R-squared:  0.1798
## F-statistic: 544.5 on 3 and 7436 DF, p-value: < 2.2e-16
```

Оценим регрессию логарифма средней почасовой зарплаты $\ln(AHE)$ на *Age*, *Female* и *Bachelor*.

R

```
model1 <- lm(log(ahe) ~ age + female + bachelor, data = dataset)
summary(model1)
```

```
##
## Call:
## lm(formula = log(ahe) ~ age + female + bachelor, data = dataset)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.28277 -0.28680  0.01372  0.30939  1.85993
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  1.941423   0.058683   33.08  <2e-16 ***
## age          0.025518   0.001953   13.07  <2e-16 ***
## female      -0.192338   0.011345  -16.95  <2e-16 ***
## bachelor     0.437783   0.011236   38.96  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4782 on 7436 degrees of freedom
## Multiple R-squared:  0.1964, Adjusted R-squared:  0.1961
## F-statistic: 605.7 on 3 and 7436 DF, p-value: < 2.2e-16
```

Оценим регрессию логарифма средней почасовой зарплаты $\ln(AHE)$ на $\ln(Age)$, *Female* и *Bachelor*.

R

```
model2 <- lm(log(ahe) ~ log(age) + female + bachelor, data = dataset)
summary(model2)
```

```
##
## Call:
## lm(formula = log(ahe) ~ log(age) + female + bachelor, data = dataset)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.27827 -0.28691  0.01326  0.30992  1.85737
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  0.14953     0.19436   0.769   0.442
## log(age)     0.75294     0.05734  13.132 <2e-16 ***
## female      -0.19236     0.01134 -16.957 <2e-16 ***
## bachelor     0.43766     0.01123  38.957 <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4782 on 7436 degrees of freedom
## Multiple R-squared:  0.1966, Adjusted R-squared:  0.1962
## F-statistic: 606.4 on 3 and 7436 DF, p-value: < 2.2e-16
```

Оценим регрессию логарифма средней почасовой зарплаты $\ln(AHE)$ на Age , Age^2 , $Female$ и $Bachelor$.

R

```
model3 <- lm(log(ahe) ~ age + I(age^2) + female + bachelor, data = dataset)
summary(model3)
```

```
##
## Call:
## lm(formula = log(ahe) ~ age + I(age^2) + female + bachelor, data = dataset)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.26705 -0.28919  0.01526  0.31090  1.85221
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  0.7918819  0.6699502   1.182   0.2372
## age          0.1040449  0.0456313   2.280   0.0226 *
## I(age^2)     -0.0013284  0.0007712  -1.722   0.0850 .
## female       -0.1923983  0.0113436 -16.961 <2e-16 ***
## bachelor      0.4374121  0.0112363  38.928 <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4782 on 7435 degrees of freedom
## Multiple R-squared:  0.1967, Adjusted R-squared:  0.1963
## F-statistic: 455.2 on 4 and 7435 DF,  p-value: < 2.2e-16
```

Начертим график функции регрессии между Age и $\ln(AHE)$ из пунктов (b), (c) и (d) для мужчин, имеющих высшее образование.

R

```

dataset_filtered <- dataset[dataset$female == 0 & dataset["bachelor"] == 1, ]

model_2f <- lm(log(ahe) ~ age, data = dataset_filtered)
ahe_2 <- predict(model_2f, dataset_filtered)


model_3f <- lm(log(ahe) ~ log(age), data = dataset_filtered)
ahe_3 <- predict(model_3f, dataset_filtered)

model_4f <- lm(log(ahe) ~ age + I(age^2), data = dataset_filtered)
ahe_4 <- predict(model_4f, dataset_filtered)

require(ggplot2)

ggplot(dataset_filtered, aes(x = age)) +
  geom_line(aes(y = ahe_2, color = "2")) +
  geom_line(aes(y = ahe_3, color = "3")) +
  geom_line(aes(y = ahe_4, color = "4")) +
  scale_color_manual(name = "", values = c("2" = "darkblue", "3" = "red", "4" =
    ↪ "darkgreen"))

```



Оценим регрессию $\ln(AHE)$ на Age , Age^2 , $Female$, $Bachelor$ и компоненту взаимодействия $Female \times Bachelor$.

R

```
model4 <- lm(log(ahe) ~ age + I(age^2) + female + bachelor + female:bachelor, data =
  ↪ dataset)
summary(model4)
```

```
##
## Call:
## lm(formula = log(ahe) ~ age + I(age^2) + female + bachelor +
##     female:bachelor, data = dataset)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.28762 -0.29105  0.01547  0.31522  1.83505
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   0.8037407   0.6693037   1.201   0.2298
## age           0.1043224   0.0455869   2.288   0.0221 *
## I(age^2)      -0.0013316   0.0007705  -1.728   0.0840 .
## female        -0.2423732   0.0170102 -14.249 < 2e-16 ***
## bachelor       0.4004463   0.0146306  27.370 < 2e-16 ***
## female:bachelor 0.0898571   0.0228090   3.940 8.24e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4777 on 7434 degrees of freedom
## Multiple R-squared:  0.1984, Adjusted R-squared:  0.1978
## F-statistic: 367.9 on 5 and 7434 DF, p-value: < 2.2e-16
```

Что эквивалентно.

R

```
model4 <- lm(log(ahe) ~ age + I(age^2) + female*bachelor, data = dataset)
summary(model4)
```

```
##
## Call:
## lm(formula = log(ahe) ~ age + I(age^2) + female * bachelor, data = dataset)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.28762 -0.29105  0.01547  0.31522  1.83505
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    0.8037407   0.6693037   1.201   0.2298
## age            0.1043224   0.0455869   2.288   0.0221 *
## I(age^2)       -0.0013316   0.0007705  -1.728   0.0840 .
## female        -0.2423732   0.0170102 -14.249 < 2e-16 ***
## bachelor       0.4004463   0.0146306  27.370 < 2e-16 ***
## female:bachelor 0.0898571   0.0228090   3.940 8.24e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4777 on 7434 degrees of freedom
## Multiple R-squared:  0.1984, Adjusted R-squared:  0.1978
## F-statistic: 367.9 on 5 and 7434 DF, p-value: < 2.2e-16
```

Оценив все эти регрессии (и любые другие, которые вы хотите оценить), сделайте выводы об эффекте влияния возраста на доходы для молодых работников.

Выведем оценки оцененных выше моделей. В силу технических ограничений выведем только `model1` и `model4`.

R

```
stargazer::stargazer(model1, model4, type = "text")
```


Python

Python

```
import numpy as np
import pandas as pd
import statsmodels.api as sm

from stargazer.stargazer import Stargazer

import matplotlib.pyplot as plt
import seaborn as sb

np.set_printoptions(legacy="1.21")
```

Загрузим данные.

Python

```
df = pd.read_excel("data/cps12.xlsx")
```

Оценим регрессию средней почасовой зарплаты (*AHE*) на возраст (*Age*), пол (*Female*) и образование (*Bachelor*).

Python

```
model0 = sm.OLS.from_formula("ahe ~ age + female + bachelor", data=df).fit()
print(model0.summary())
```

```
##                               OLS Regression Results
## =====
## Dep. Variable:                ahe    R-squared:                0.180
## Model:                      OLS    Adj. R-squared:           0.180
## Method:                    Least Squares    F-statistic:             544.5
## Date:                      Ср, 02 июл 2025    Prob (F-statistic):       6.51e-320
## Time:                      21:41:03    Log-Likelihood:          -27443.
## No. Observations:          7440    AIC:                     5.489e+04
## Df Residuals:              7436    BIC:                     5.492e+04
## Df Model:                   3
## Covariance Type:           nonrobust
## =====
##               coef    std err          t      P>|t|      [0.025    0.975]
## -----
## Intercept         1.8662      1.188       1.571     0.116     -0.462     4.194
## age               0.5103      0.040     12.912     0.000      0.433     0.588
## female            -3.8103      0.230    -16.596     0.000     -4.260    -3.360
## bachelor          8.3186      0.227     36.584     0.000      7.873     8.764
## =====
## Omnibus:                1975.582    Durbin-Watson:           1.935
## Prob(Omnibus):          0.000    Jarque-Bera (JB):        6089.399
## Skew:                   1.360    Prob(JB):                 0.00
## Kurtosis:               6.499    Cond. No.                 316.
## =====
##
## Notes:
## [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
```

Оценим регрессию логарифма средней почасовой зарплаты $\ln(AHE)$ на *Age*, *Female* и *Bachelor*.

Python

```
model1 = sm.OLS.from_formula("np.log(ahe) ~ age + female + bachelor", data=df).fit()
print(model1.summary())
```

```
##                                OLS Regression Results
## =====
## Dep. Variable:                np.log(ahe)    R-squared:                0.196
## Model:                        OLS           Adj. R-squared:        0.196
## Method:                       Least Squares   F-statistic:             605.7
## Date:                          Cp, 02 июл 2025   Prob (F-statistic):       0.00
## Time:                          21:41:03       Log-Likelihood:          -5066.6
## No. Observations:              7440          AIC:                    1.014e+04
## Df Residuals:                  7436          BIC:                    1.017e+04
## Df Model:                      3
## Covariance Type:              nonrobust
## =====
##               coef      std err          t      P>|t|      [0.025      0.975]
## -----
## Intercept      1.9414      0.059      33.083      0.000      1.826      2.056
## age            0.0255      0.002      13.067      0.000      0.022      0.029
## female        -0.1923      0.011     -16.953      0.000     -0.215     -0.170
## bachelor       0.4378      0.011      38.964      0.000      0.416      0.460
## =====
## Omnibus:                316.825   Durbin-Watson:           1.936
## Prob(Omnibus):           0.000   Jarque-Bera (JB):        508.141
## Skew:                   -0.375   Prob(JB):                4.56e-111
## Kurtosis:                4.037   Cond. No.:               316.
## =====
##
## Notes:
## [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
```

Оценим регрессию логарифма средней почасовой зарплаты $\ln(AHE)$ на $\ln(Age)$, *Female* и *Bachelor*.

Python

```
model2 = sm.OLS.from_formula("np.log(ahe) ~ np.log(age) + female + bachelor",
    ↪ data=df).fit()
print(model2.summary())
```

```
##                               OLS Regression Results
## =====
## Dep. Variable:                np.log(ahe)    R-squared:                0.197
## Model:                      OLS            Adj. R-squared:         0.196
## Method:                     Least Squares   F-statistic:             606.4
## Date:                       Ср, 02 июл 2025  Prob (F-statistic):    0.00
## Time:                       21:41:03       Log-Likelihood:          -5065.8
## No. Observations:            7440          AIC:                  1.014e+04
## Df Residuals:                7436          BIC:                  1.017e+04
## Df Model:                    3
## Covariance Type:             nonrobust
## =====
##                               coef    std err          t      P>|t|      [0.025    0.975]
## -----
## Intercept                   0.1495     0.194      0.769     0.442    -0.231     0.531
## np.log(age)                 0.7529     0.057    13.132     0.000     0.641     0.865
## female                     -0.1924     0.011   -16.957     0.000    -0.215    -0.170
## bachelor                   0.4377     0.011    38.957     0.000     0.416     0.460
## =====
## Omnibus:                     316.790    Durbin-Watson:           1.936
## Prob(Omnibus):               0.000    Jarque-Bera (JB):        508.147
## Skew:                       -0.375    Prob(JB):                4.54e-111
## Kurtosis:                    4.037    Cond. No.                131.
## =====
##
## Notes:
## [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
```

Оценим регрессию логарифма средней почасовой зарплаты $\ln(AHE)$ на Age , Age^2 , $Female$ и $Bachelor$.

Python

```
model3 = sm.OLS.from_formula("np.log(ahe) ~ age + I(age**2) + female + bachelor",
    ↪ data=df).fit()
print(model3.summary())
```



```

##                                OLS Regression Results
## =====
## Dep. Variable:                np.log(ahe)    R-squared:                0.197
## Model:                        OLS           Adj. R-squared:          0.196
## Method:                       Least Squares   F-statistic:             455.2
## Date:                         Ср, 02 июл 2025   Prob (F-statistic):       0.00
## Time:                         21:41:04         Log-Likelihood:          -5065.1
## No. Observations:              7440          AIC:                    1.014e+04
## Df Residuals:                  7435          BIC:                    1.017e+04
## Df Model:                      4
## Covariance Type:              nonrobust
## =====
##               coef      std err          t      P>|t|      [0.025      0.975]
## -----
## Intercept      0.7919      0.670        1.182      0.237      -0.521      2.105
## age            0.1040      0.046        2.280      0.023       0.015      0.193
## I(age ** 2)   -0.0013      0.001       -1.722      0.085      -0.003      0.000
## female        -0.1924      0.011     -16.961      0.000      -0.215     -0.170
## bachelor       0.4374      0.011     38.928      0.000       0.415      0.459
## =====
## Omnibus:                316.471   Durbin-Watson:           1.935
## Prob(Omnibus):           0.000   Jarque-Bera (JB):        507.649
## Skew:                    -0.375   Prob(JB):                5.83e-111
## Kurtosis:                4.037   Cond. No.:               1.09e+05
## =====
##
## Notes:
## [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
## [2] The condition number is large, 1.09e+05. This might indicate that there are
## strong multicollinearity or other numerical problems.

```

Начертим график функции регрессии между *Age* и $\ln(AHE)$ из пунктов (b), (c) и (d) для мужчин, имеющих высшее образование.

Python


```
dataset_filtered = df.loc[(df.female == 0) & (df.bachelor == 1), ].copy()

ahe_2 = (
    sm.OLS.from_formula("np.log(ahe) ~ age", data=dataset_filtered).
    fit().
    predict()
)

ahe_3 = (
    sm.OLS.from_formula("np.log(ahe) ~ np.log(age)", data=dataset_filtered).
    fit().
    predict()
)

ahe_4 = (
    sm.OLS.from_formula("np.log(ahe) ~ age + I(age**2)", data=dataset_filtered).
    fit().
    predict()
)

plt.clf()
sb.lineplot(x=dataset_filtered.age, y=ahe_2, label="2")
sb.lineplot(x=dataset_filtered.age, y=ahe_3, label="3")
sb.lineplot(x=dataset_filtered.age, y=ahe_4, label="4")
plt.show()
```



Оценим регрессию $\ln(AHE)$ на Age , Age^2 , $Female$, $Bachelor$ и компоненту взаимодействия $Female \times Bachelor$.

Python

```
model4 = sm.OLS.from_formula("np.log(ahe) ~ age + I(age**2) + female + bachelor +  
↪ female:bachelor", data=df).fit()  
print(model4.summary())
```

```
##                                OLS Regression Results
## =====
## Dep. Variable:                np.log(ahe)    R-squared:                0.198
## Model:                        OLS           Adj. R-squared:        0.198
## Method:                      Least Squares  F-statistic:             367.9
## Date:                        Ср, 02 июл 2025 Prob (F-statistic):       0.00
## Time:                        21:41:05       Log-Likelihood:          -5057.4
## No. Observations:            7440          AIC:                  1.013e+04
## Df Residuals:                7434          BIC:                  1.017e+04
## Df Model:                    5
## Covariance Type:             nonrobust
## =====
##                                coef    std err          t      P>|t|      [0.025    0.975]
## -----
## Intercept                    0.8037     0.669      1.201     0.230     -0.508     2.116
## age                          0.1043     0.046     2.288     0.022      0.015     0.194
## I(age ** 2)                 -0.0013     0.001    -1.728     0.084     -0.003     0.000
## female                      -0.2424     0.017   -14.249     0.000     -0.276    -0.209
## bachelor                     0.4004     0.015    27.370     0.000      0.372     0.429
## female:bachelor              0.0899     0.023     3.940     0.000      0.045     0.135
## =====
## Omnibus:                     319.786    Durbin-Watson:           1.933
## Prob(Omnibus):                0.000    Jarque-Bera (JB):        511.678
## Skew:                        -0.379    Prob(JB):                7.77e-112
## Kurtosis:                     4.038    Cond. No.                1.09e+05
## =====
##
## Notes:
## [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
## [2] The condition number is large, 1.09e+05. This might indicate that there are
## strong multicollinearity or other numerical problems.
```

Что эквивалентно.

Python

```
model4 = sm.OLS.from_formula("np.log(ahe) ~ age + I(age**2) + female*bachelor",
    ↪ data=df).fit()
print(model4.summary())
```

```
##                                OLS Regression Results
## =====
## Dep. Variable:                np.log(ahe)    R-squared:                0.198
## Model:                        OLS           Adj. R-squared:         0.198
## Method:                       Least Squares  F-statistic:             367.9
## Date:                         Ср, 02 июл 2025  Prob (F-statistic):      0.00
## Time:                         21:41:05      Log-Likelihood:          -5057.4
## No. Observations:             7440          AIC:                   1.013e+04
## Df Residuals:                 7434          BIC:                   1.017e+04
## Df Model:                     5
## Covariance Type:              nonrobust
## =====
##                                coef    std err          t      P>|t|      [0.025     0.975]
## -----
## Intercept                    0.8037     0.669        1.201     0.230     -0.508     2.116
## age                          0.1043     0.046        2.288     0.022      0.015     0.194
## I(age ** 2)                  -0.0013    0.001       -1.728     0.084     -0.003     0.000
## female                       -0.2424     0.017     -14.249     0.000     -0.276    -0.209
## bachelor                     0.4004     0.015     27.370     0.000      0.372     0.429
## female:bachelor              0.0899     0.023      3.940     0.000      0.045     0.135
## =====
## Omnibus:                     319.786    Durbin-Watson:           1.933
## Prob(Omnibus):                0.000    Jarque-Bera (JB):        511.678
## Skew:                         -0.379    Prob(JB):                7.77e-112
## Kurtosis:                     4.038    Cond. No.:               1.09e+05
## =====
##
## Notes:
## [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
## [2] The condition number is large, 1.09e+05. This might indicate that there are
## strong multicollinearity or other numerical problems.
```

Оценив все эти регрессии (и любые другие, которые вы хотите оценить), сделайте выводы об эффекте влияния возраста на доходы для молодых работников.

Выведем оценки оцененных выше моделей. В силу технических ограничений выведем только model1 и model4.

Python

```
import yatg
print(yatg.html_2_ascii_table(
    Stargazer([model1, model4]).render_html()
))
```

```

## | | | |
## |-----+-----+-----+
## | | Dependent variable: np.log(ahe) | |
## | | | |
## | | (1) | (2) |
## | | | |
## | I(age ** 2) | | -0.001* |
## | | | | (0.001) |
## | Intercept | 1.941*** | 0.804 |
## | | | | (0.059) | (0.669) |
## | age | 0.026*** | 0.104** |
## | | | | (0.002) | (0.046) |
## | bachelor | 0.438*** | 0.400*** |
## | | | | (0.011) | (0.015) |
## | female | -0.192*** | -0.242*** |
## | | | | (0.011) | (0.017) |
## | female:bachelor | | 0.090*** |
## | | | | (0.023) |
## | | | |
## | Observations | 7440 | 7440 |
## | R2 | 0.196 | 0.198 |
## | Adjusted R2 | 0.196 | 0.198 |
## | Residual Std. Error | 0.478 (df=7436) | 0.478 (df=7434) |
## | F Statistic | 605.726*** (df=3; 7436) | 367.940*** (df=5; 7434) |
## | | | |
## | Note: | *p<0.1; **p<0.05; ***p<0.01 |

```

Практическое упражнение №2

(СУ, Е8.2) Используя базу данных **Growth**, описанную в **Е4.4**, за исключением данных для Мальты, оцените следующие пять регрессий переменной *Growth* на:

- 1) *TradeShare* и *YearsSchool*;
- 2) *TradeShare* и $\ln(\text{YearSchool})$;
- 3) *TradeShare*, $\ln(\text{YearSchool})$, *Rev_Coups*, *Assasinations* и $\ln(\text{RGDP60})$;
- 4) *TradeShare*, $\ln(\text{YearSchool})$, *Rev_Coups*, *Assasinations*, $\ln(\text{RGDP60})$ и $\text{TradeShare} \times \ln(\text{YearSchool})$;
- 5) *TradeShare*, TradeShare^2 , TradeShare^3 , $\ln(\text{YearSchool})$, *Rev_Coups*, *Assasinations* и $\ln(\text{RGDP60})$.

- a. Постройте диаграмму рассеяния переменных *Growth* и *YearsSchool*. Кажется ли полученное соотношение линейным или нет? Объясните. Ис-

- пользуйте график для объяснения, почему регрессия (2) подходит для описания данных лучше, чем регрессия (1).
- б. В 1960 году страна намеревалась провести образовательную политику, которая увеличит среднюю продолжительность обучения с 4 лет до 6 лет. Используйте регрессию (1), чтобы рассчитать предсказанный рост *Growth*. Используйте регрессию (2), чтобы рассчитать предсказанный рост *Growth*.
- в. Проверьте, равны ли коэффициенты при *Assassinations* и *Rev_Coups* нулю, используя регрессию (3).
- г. Используя регрессию (4), скажите, существует ли свидетельство того, что эффект влияния *TradeShare* на *Growth* зависит от уровня образования в стране?
- д. Используя регрессию (5), скажите, существует ли свидетельство нелинейности эффекта влияния *TradeShare* на *Growth*?
- е. В 1960 году страна намеревалась провести торговую политику, которая увеличит среднее значение *TradeShare* с 0.5 до 1. Используйте регрессию (3), чтобы рассчитать предсказанный рост *Growth*. Используйте регрессию (5), чтобы рассчитать предсказанный рост *Growth*.

R

Загрузим данные, отфильтруем их и оценим предложенные модели.

R

```
dataset <- readxl::read_excel("data/Growth.xlsx")
dataset <- dataset[dataset$country_name != "Malta", ]

model0 <- lm(growth ~ tradeshare + yearsschool, data = dataset)
summary(model0)
```

```
##
## Call:
## lm(formula = growth ~ tradeshare + yearsschool, data = dataset)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.4896 -0.9538 -0.3304  0.7680  5.5663
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -0.1222     0.6627  -0.184  0.85426
## tradeshare    1.8978     0.9361   2.027  0.04699 *
## yearsschool   0.2430     0.0837   2.903  0.00514 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.691 on 61 degrees of freedom
## Multiple R-squared:  0.1606, Adjusted R-squared:  0.1331
## F-statistic: 5.836 on 2 and 61 DF,  p-value: 0.004796
```

R

```
model1 <- lm(growth ~ tradeshare + log(yearsschool), data = dataset)
summary(model1)
```

```
##
## Call:
## lm(formula = growth ~ tradeshare + log(yearsschool), data = dataset)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.6162 -0.9887 -0.2074  0.7479  5.2958
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   -0.1857     0.5643  -0.329  0.7432
## tradeshare     1.7490     0.8600   2.034  0.0463 *
## log(yearsschool) 1.0163     0.2231   4.556 2.56e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.558 on 61 degrees of freedom
## Multiple R-squared:  0.2872, Adjusted R-squared:  0.2638
## F-statistic: 12.29 on 2 and 61 DF,  p-value: 3.282e-05
```


R

```
model2 <- lm(growth ~ tradeshare + log(yearsschool) + rev_coups + assassinations +
  ↪ log(rgdp60), data = dataset)
summary(model2)
```

```
##
## Call:
## lm(formula = growth ~ tradeshare + log(yearsschool) + rev_coups +
##   assassinations + log(rgdp60), data = dataset)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.2482 -0.9214 -0.0839  0.7938  4.1158
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    11.7459     2.9198   4.023 0.000168 ***
## tradeshare       1.1035     0.8332   1.325 0.190528
## log(yearsschool)  2.1613     0.3627   5.960 1.59e-07 ***
## rev_coups      -2.2995     1.0045  -2.289 0.025719 *
## assassinations   0.2277     0.4337   0.525 0.601501
## log(rgdp60)     -1.6211     0.3985  -4.068 0.000145 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.4 on 58 degrees of freedom
## Multiple R-squared:  0.4532, Adjusted R-squared:  0.406
## F-statistic: 9.613 on 5 and 58 DF, p-value: 1.012e-06
```

R

```
model3 <- lm(growth ~ rev_coups + assassinations + log(rgdp60) + tradeshare *
  ↪ log(yearsschool), data = dataset)
summary(model3)
```

```
##
## Call:
## lm(formula = growth ~ rev_coups + assassinations + log(rgdp60) +
##     tradeshare * log(yearsschool), data = dataset)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.0681 -0.9281 -0.0606  0.7652  4.1068
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)      11.4985     2.9599   3.885 0.000269 ***
## rev_coups         -2.3502     1.0127  -2.321 0.023900 *
## assassinations     0.2242     0.4359   0.514 0.608998
## log(rgdp60)       -1.6414     0.4018  -4.085 0.000139 ***
## tradeshare         1.8828     1.4753   1.276 0.207051
## log(yearsschool)   2.5247     0.6736   3.748 0.000418 ***
## tradeshare:log(yearsschool) -0.6901     1.0756  -0.642 0.523706
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.407 on 57 degrees of freedom
## Multiple R-squared:  0.4571, Adjusted R-squared:  0.3999
## F-statistic: 7.998 on 6 and 57 DF, p-value: 2.803e-06
```

R


```
model4 <- lm(growth ~ tradeshare + I(tradeshare^2) + I(tradeshare^3) +
  ↪ log(yearsschool) + rev_coups + assassinations + log(rgdp60), data = dataset)
summary(model4)
```

```
##
## Call:
## lm(formula = growth ~ tradeshare + I(tradeshare^2) + I(tradeshare^3) +
##     log(yearsschool) + rev_coups + assassinations + log(rgdp60),
##     data = dataset)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.2438 -0.8381 -0.1331  0.6846  4.2607
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    12.9291     3.0985   4.173 0.000106 ***
## tradeshare      -5.7019     9.7551  -0.585 0.561226
## I(tradeshare^2)   8.4879    17.4350   0.487 0.628280
## I(tradeshare^3)  -2.7597     9.2498  -0.298 0.766535
## log(yearsschool)  2.1332     0.3670   5.813 3.05e-07 ***
## rev_coups       -2.0355     1.0259  -1.984 0.052168 .
## assassinations    0.1021     0.4435   0.230 0.818747
## log(rgdp60)     -1.5843     0.4079  -3.884 0.000274 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.401 on 56 degrees of freedom
## Multiple R-squared:  0.4711, Adjusted R-squared:  0.405
## F-statistic: 7.126 on 7 and 56 DF, p-value: 4.38e-06
```

Постройте диаграмму рассеяния переменных *Growth* и *YearsSchool*.

R


```
plot(dataset$yearsschool, dataset$growth)
```



Можно воспользоваться менеджером контекста.

R

```
with(dataset, plot(yearsschool, growth))
```



В 1960 году страна намеревалась провести образовательную политику, которая увеличит среднюю продолжительность обучения с 4 лет до 6 лет. Используйте регрессию (1), чтобы рассчитать предсказанный рост *Growth*. Используйте регрессию (2), чтобы рассчитать предсказанный рост *Growth*.

R

```
model0$coefficients["yearsschool"] * (6 - 4)
```

```
## yearsschool
## 0.4859505
```

R

```
model1$coefficients["log(yearsschool)"] * (log(6) - log(4))
```

```
## log(yearsschool)
## 0.4120708
```

Проверьте, равны ли коэффициенты при *Assassinations* и *Rev_Coups* нулю, используя регрессию (3).

R

```
car::linearHypothesis(model2, c("rev_coups=0", "assasinations=0"))
```

```
##
## Linear hypothesis test:
## rev_coups = 0
## assasinations = 0
##
## Model 1: restricted model
## Model 2: growth ~ tradeshare + log(yearsschool) + rev_coups + assasinations +
##   log(rgdp60)
##
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1      60 124.72
## 2      58 113.64  2    11.081 2.828 0.06731 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

В 1960 году страна намеревалась провести торговую политику, которая увеличит среднее значение *TradeShare* с 0.5 до 1. Используйте регрессию (3), чтобы рассчитать предсказанный рост *Growth*. Используйте регрессию (5), чтобы рассчитать предсказанный рост *Growth*.

R

```
model2$coefficients["tradeshare"] * (1 - 0.5)
```

```
## tradeshare
## 0.551765
```

R

```
model4$coefficients["tradeshare"] * (1 - 0.5) +
  model4$coefficients["I(tradeshare^2)"] * (1 - 0.25) +
  model4$coefficients["I(tradeshare^3)"] * (1 - 0.125)
```

```
## tradeshare
## 1.100167
```

Python

Python

```
import numpy as np
import pandas as pd
import seaborn as sns
import statsmodels.formula.api as sms

np.set_printoptions(legacy="1.21")
```

Загрузим данные, отфильтруем их и оценим предложенные модели.

Python

```
df = pd.read_excel("data/Growth.xlsx")
df = df.loc[df.country_name != "Malta", :]

model0 = sms.ols("growth ~ tradeshare + yearsschool", data=df).fit()
print(model0.summary())
```

```
##                                OLS Regression Results
## =====
## Dep. Variable:                growth    R-squared:                0.161
## Model:                      OLS        Adj. R-squared:         0.133
## Method:                     Least Squares    F-statistic:             5.836
## Date:                       Cp, 02 июл 2025    Prob (F-statistic):      0.00480
## Time:                       21:41:13    Log-Likelihood:          -122.90
## No. Observations:           64        AIC:                    251.8
## Df Residuals:               61        BIC:                    258.3
## Df Model:                   2
## Covariance Type:            nonrobust
## =====
##               coef    std err          t      P>|t|      [0.025    0.975]
## -----
## Intercept      -0.1222     0.663     -0.184     0.854     -1.447     1.203
## tradeshare      1.8978     0.936     2.027     0.047     0.026     3.770
## yearsschool     0.2430     0.084     2.903     0.005     0.076     0.410
## =====
## Omnibus:                10.227    Durbin-Watson:           2.156
## Prob(Omnibus):          0.006    Jarque-Bera (JB):        10.906
## Skew:                   0.745    Prob(JB):                0.00428
## Kurtosis:               4.368    Cond. No.:               24.9
## =====
##
## Notes:
## [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
```

Python

```
model1 = sms.ols("growth ~ tradeshare + np.log(yearsschool)", data=df).fit()
print(model1.summary())
```

```
##                               OLS Regression Results
## =====
## Dep. Variable:                growth    R-squared:                0.287
## Model:                      OLS        Adj. R-squared:         0.264
## Method:                     Least Squares    F-statistic:             12.29
## Date:                       Ср, 02 июл 2025    Prob (F-statistic):      3.28e-05
## Time:                       21:41:13        Log-Likelihood:          -117.67
## No. Observations:           64            AIC:                    241.3
## Df Residuals:               61            BIC:                    247.8
## Df Model:                   2
## Covariance Type:            nonrobust
## =====
##                               coef      std err          t      P>|t|      [0.025      0.975]
## -----
## Intercept                   -0.1857      0.564      -0.329      0.743      -1.314      0.943
## tradeshare                   1.7490      0.860       2.034      0.046       0.029      3.469
## np.log(yearsschool)          1.0163      0.223       4.556      0.000       0.570      1.462
## =====
## Omnibus:                     14.404    Durbin-Watson:           2.127
## Prob(Omnibus):                0.001    Jarque-Bera (JB):        16.497
## Skew:                        1.006    Prob(JB):                0.000262
## Kurtosis:                     4.461    Cond. No.                 8.69
## =====
##
## Notes:
## [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
```

Python

```
model2 = sms.ols("growth ~ tradeshare + np.log(yearsschool) + rev_coups +
↳ assassinations + np.log(rgdp60)", data=df).fit()
print(model2.summary())
```



```
##                                OLS Regression Results
## =====
## Dep. Variable:                growth    R-squared:                0.453
## Model:                        OLS      Adj. R-squared:         0.406
## Method:                       Least Squares    F-statistic:             9.613
## Date:                         Ср, 02 июл 2025    Prob (F-statistic):      1.01e-06
## Time:                         21:41:13    Log-Likelihood:          -109.18
## No. Observations:              64    AIC:                     230.4
## Df Residuals:                  58    BIC:                     243.3
## Df Model:                      5
## Covariance Type:              nonrobust
## =====
##                                coef    std err          t      P>|t|      [0.025    0.975]
## -----
## Intercept                    11.7459      2.920      4.023      0.000      5.901     17.591
## tradeshare                   1.1035      0.833      1.325      0.191     -0.564      2.771
## np.log(yearsschool)          2.1613      0.363      5.960      0.000      1.435      2.887
## rev_coups                   -2.2995      1.004     -2.289      0.026     -4.310     -0.289
## assassinations               0.2277      0.434      0.525      0.602     -0.640      1.096
## np.log(rgdp60)              -1.6211      0.399     -4.068      0.000     -2.419     -0.823
## =====
## Omnibus:                      3.780    Durbin-Watson:           1.966
## Prob(Omnibus):                0.151    Jarque-Bera (JB):        2.930
## Skew:                         0.379    Prob(JB):                0.231
## Kurtosis:                     3.724    Cond. No.                136.
## =====
##
## Notes:
## [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
```

Python

```
model3 = sms.ols("growth ~ rev_coups + assassinations + np.log(rgdp60) + tradeshare *
↪ np.log(yearsschool)", data=df).fit()
print(model3.summary())
```

```
##                                OLS Regression Results
## =====
## Dep. Variable:                growth    R-squared:                0.457
## Model:                      OLS        Adj. R-squared:         0.400
## Method:                     Least Squares    F-statistic:             7.998
## Date:                       Ср, 02 июл 2025    Prob (F-statistic):      2.80e-06
## Time:                       21:41:13        Log-Likelihood:          -108.95
## No. Observations:           64            AIC:                    231.9
## Df Residuals:                57            BIC:                    247.0
## Df Model:                    6
## Covariance Type:            nonrobust
## =====
##                                coef      std err          t      P>|t|      [0.025     0.975]
## -----
## Intercept                    11.4985      2.960        3.885      0.000        5.571     17.426
## rev_coups                    -2.3502      1.013       -2.321      0.024       -4.378     -0.322
## assassinations                0.2242      0.436        0.514      0.609       -0.649      1.097
## np.log(rgdp60)               -1.6414      0.402       -4.085      0.000       -2.446     -0.837
## tradeshare                    1.8828      1.475        1.276      0.207       -1.071      4.837
## np.log(yearsschool)           2.5247      0.674        3.748      0.000        1.176      3.874
## tradeshare:np.log(yearsschool) -0.6901      1.076       -0.642      0.524       -2.844      1.464
## =====
## Omnibus:                     4.112    Durbin-Watson:           1.979
## Prob(Omnibus):                0.128    Jarque-Bera (JB):        3.221
## Skew:                         0.423    Prob(JB):                 0.200
## Kurtosis:                     3.701    Cond. No.                 138.
## =====
##
## Notes:
## [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
```

Python


```
model4 = sms.ols("growth ~ tradeshare + I(tradeshare**2) + I(tradeshare**3) +
    ↪ np.log(yearsschool) + rev_coups + assassinations + np.log(rgdp60)", data=df).fit()
print(model4.summary())
```

```
##                                OLS Regression Results
## =====
## Dep. Variable:                growth    R-squared:                0.471
## Model:                        OLS      Adj. R-squared:         0.405
## Method:                      Least Squares    F-statistic:             7.126
## Date:                        Ср, 02 июл 2025    Prob (F-statistic):      4.38e-06
## Time:                        21:41:13    Log-Likelihood:          -108.12
## No. Observations:            64      AIC:                    232.2
## Df Residuals:                56      BIC:                    249.5
## Df Model:                    7
## Covariance Type:            nonrobust
## =====
##                                coef      std err          t      P>|t|      [0.025      0.975]
## -----
## Intercept                    12.9291      3.098        4.173      0.000        6.722     19.136
## tradeshare                   -5.7019      9.755       -0.585      0.561     -25.244     13.840
## I(tradeshare ** 2)           8.4879     17.435        0.487      0.628     -26.439     43.414
## I(tradeshare ** 3)          -2.7597      9.250       -0.298      0.767     -21.289     15.770
## np.log(yearsschool)          2.1332      0.367        5.813      0.000        1.398      2.868
## rev_coups                   -2.0355      1.026       -1.984      0.052     -4.091      0.020
## assassinations               0.1021      0.444        0.230      0.819     -0.786      0.991
## np.log(rgdp60)              -1.5843      0.408       -3.884      0.000     -2.402     -0.767
## =====
## Omnibus:                     7.017    Durbin-Watson:           2.030
## Prob(Omnibus):               0.030    Jarque-Bera (JB):        6.867
## Skew:                        0.544    Prob(JB):                0.0323
## Kurtosis:                    4.179    Cond. No.:               994.
## =====
##
## Notes:
## [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
```

Постройте диаграмму рассеяния переменных *Growth* и *YearsSchool*.

Python

```
sns.scatterplot(x="yearsschool", y="growth", data=df)
```



В 1960 году страна намеревалась провести образовательную политику, которая увеличит среднюю продолжительность обучения с 4 лет до 6 лет. Используйте регрессию (1), чтобы рассчитать предсказанный рост *Growth*. Используйте регрессию (2), чтобы рассчитать предсказанный рост *Growth*.

Python

```
model0.params["yearsschool"] * (6 - 4)
```

```
## 0.48595053073684014
```

Python

```
model1.params["np.log(yearsschool)"] * (np.log(6) - np.log(4))
```

```
## 0.41207075284777006
```

Проверьте, равны ли коэффициенты при *Assassinations* и *Rev_Coups* нулю, используя регрессию (3).

Python

```
model2.f_test("rev_coups=0, assassinations=0")
```

```
## <class 'statsmodels.stats.contrast.ContrastResults'>  
## <F test: F=2.8279610813701614, p=0.06731102549280178, df_denom=58, df_num=2>
```

В 1960 году страна намеревалась провести торговую политику, которая увеличит среднее значение *TradeShare* с 0.5 до 1. Используйте регрессию (3), чтобы рассчитать предсказанный рост *Growth*. Используйте регрессию (5), чтобы рассчитать предсказанный рост *Growth*.

Python

```
model2.params["tradeshare"] * (1 - 0.5)
```

```
## 0.5517649687310129
```

Python

```
model4.params["tradeshare"] * (1 - 0.5) + model4.params["I(tradeshare ** 2)"] * (1 -  
→ 0.25) + model4.params["I(tradeshare ** 3)"] * (1 - 0.125)
```

```
## 1.1001665649418149
```


Список литературы

Mittelhammer R. C., Judge G. G., Miller D. J. Econometric Foundations. — Cambridge : Cambridge University Press, 2000.

Сток Д., Уотсон М. Введение в эконометрику. — Москва : Издательский дом «Дело» РАНХиГС, 2015. — 864 с.

