

Ликбез: Контрольные и инструментальные переменные

Зямалов В.Е.

Кириллова М.А.

1. Контрольные переменные

Наша цель — получить несмещенные оценки интересующего нас коэффициента при постоянстве факторов, на которые мы не можем влиять.

В наблюдаемых (не экспериментальных) данных u_i зависит от всех прочих факторов.

- Если мы можем наблюдать эти прочие факторы, то мы включаем эти переменные в регрессию.
- *Очень часто мы не наблюдаем прочие факторы*; например, вовлеченность родителей в образовательный процесс.

В этом случае можно включить «контрольные переменные», которые коррелированы с пропущенными факторами, влияющими на зависимую переменную, но сами факторами, влияющими на зависимую переменную, могут не являться.

Контрольная переменная W — это переменная, которая коррелирована с пропущенным фактором («контролирует на него») в регрессии Y на X , но сама не обязательно влияет на Y (вызывает изменения в Y).

Три характеристики эффективности контрольной переменной:

1. Эффективная контрольная переменная при включении в регрессию делает интересующую нас переменную не коррелированной со случайной ошибкой.
2. В предположении постоянства контрольной(ых) переменной(ых) интересующая нас переменная «как бы» случайно задана.
3. Среди объектов с одинаковыми значениями контрольной(ых) переменной(ых), интересующая нас переменная не коррелирована с пропущенными факторами, влияющими на Y .

1.1. Независимость условного среднего

Так как контрольная переменная **коррелирована** со случайной ошибкой u_i , то очевидно, что первая предпосылка МНК не выполняется, то есть, в общем случае, коэффициент при контрольной переменной *смещен*!

Поэтому при использовании контрольных переменных первую предпосылку МНК меняют на следующее утверждение:

W_i — *эффективная контрольная переменная*, если выполняется условие независимости условного среднего:

$$E(u_i | X_i, W_i) = E(u_i | W_i)$$

1.2. Свойства оценок коэффициентов

Рассмотрим модель

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 W_i + u_i \quad (1)$$

где X_i — интересующая нас переменная, а W_i — эффективная контрольная переменная.

При выполнении условия независимости условного среднего и 2–4 предположений МНК, то:

1. β_1 имеет причинно-следственную интерпретацию,
2. $\hat{\beta}_1$ не смещена,
3. $\hat{\beta}_2$, в общем случае, смещена.

1.2.1. β_1 имеет причинно-следственную интерпретацию

Ожидаемое изменение Y — результат изменения X при постоянстве W , т.е.

$$\begin{aligned} E(Y | X = x + \Delta x, W = w) - E(Y | X = x, W = w) &= \\ &= [\beta_0 + \beta_1(x + \Delta x) + \beta_2 w + E(u | X = x + \Delta x, W = w)] - \\ &\quad - [\beta_0 + \beta_1 x + \beta_2 w + E(u | X = x, W = w)] = \\ &= \beta_1 \Delta x + [E(u | X = x + \Delta x, W = w) - E(u | X = x, W = w)] = \beta_1 \Delta x \end{aligned}$$

где последнее равенство следует из условия независимости условного среднего.

1.2.2. Смещенность/несмещенность

Пусть (для удобства) $E(u_i | X_i, W_i) = E(u_i | W_i) = \gamma_0 + \gamma_2 W_i$.

Пусть $v_i = u_i - E(u_i | X_i, W_i)$. Тогда $E(v_i | X_i, W_i) = 0$.

$$u_i = E(u_i | X_i, W_i) + v_i = \gamma_0 + \gamma_2 W_i + v_i \quad (2)$$

Подставляя (2) в (1) получаем

$$\begin{aligned} Y_i &= \beta_0 + \beta_1 X_i + \beta_2 W_i + \gamma_0 + \gamma_2 W_i + v_i = \\ &= (\beta_0 + \gamma_0) + \beta_1 X_i + (\beta_2 + \gamma_2) W_i + v_i = \\ &= \delta_0 + \beta_1 X_i + \delta_2 W_i + v_i \end{aligned} \quad (3)$$

Так как $E(v_i | X_i, W_i) = 0$, то уравнение (3) удовлетворяет первому условию МНК $\Rightarrow$ МНК оценки δ_0 , β_1 и δ_2 не смещены.

Так как регрессоры в (1) и (3) одинаковы, то *de facto* оценивается (3), то есть

$$\begin{aligned} E(\hat{\beta}_1) &= \beta_1 \\ E(\hat{\beta}_2) &= \delta_2 = \beta_2 + \gamma_2 \neq \beta_2 \end{aligned}$$

2. Инструментальные переменные

Метод инструментальных переменных призван решить проблему со смещенностью оценок коэффициентов при невыполнении первой предпосылки МНК. Он позволяет получить *состоятельные*, но, в общем случае, *смещенные*, оценки коэффициентов при наличии корреляции между регрессором и случайной ошибкой.

2.1. Парная регрессия с инструментальной переменной

$$\begin{aligned} Y_i &= \beta_0 + \beta_1 X_i + u_i \\ \text{Cov}(u_i, X_i) &\neq 0 \end{aligned} \quad (4)$$

$\hat{\beta}_1$ — смещенная и несостоятельная оценка β_1 .

Что можно сделать? Ввести *инструмент* Z_i , позволяющий «изолировать» коррелированную с u_i часть X_i .

Переменная X_i называется *эндогенной*, так как она коррелирует со случайной ошибкой; а вот переменная Z_i , не коррелирующая с u_i называется *экзогенной*.

Для того, чтобы мы могли использовать инструмент Z_i , он должен быть «хорошим»: допустимым или подходящим — то есть удовлетворяющим следующим свойствам:

релевантность $\text{Cov}(X_i, Z_i) \neq 0$

экзогенность $\text{Cov}(u_i, Z_i) = 0$

2.1.1. Оценивание коэффициентов

Шаг 1 Разложение X_i на 2 части: оцениваем вспомогательную регрессию X_i на Z_i

$$X_i = \pi_0 + \pi_1 Z_i + v_i$$

$$\hat{\pi}_1 = \frac{s_{XZ}}{s_Z^2}$$

$$\hat{X}_i = \hat{\pi}_0 + \hat{\pi}_1 Z_i$$

Так как $\text{Cov}(u_i, Z_i) = 0$, то и $\text{Cov}(u_i, \hat{X}_i) = 0$.

Шаг 2 Заменяем X_i в (4) на подобранные значения $\hat{X}_i$:

$$\begin{aligned} Y_i &= \beta_0 + \beta_1 \hat{X}_i + u_i \\ \hat{\beta}_1^{TSLs} &= \frac{\sum_{i=1}^n (Y_i - \bar{Y})(\hat{X}_i - \bar{X})}{\sum_{i=1}^n (\hat{X}_i - \bar{X})^2} \\ &= \frac{\frac{s_{XZ}}{s_Z^2} \sum_{i=1}^n (Y_i - \bar{Y})(Z_i - \bar{Z})}{\left(\frac{s_{XZ}}{s_Z^2}\right)^2 \sum_{i=1}^n (Z_i - \bar{Z})^2} = \\ &= \frac{\frac{s_{XZ}}{s_Z^2} s_{YZ}}{\frac{s_{XZ}^2}{s_Z^4} s_Z^2} = \frac{s_{YZ}}{s_{XZ}} \end{aligned}$$

Здесь используем свойство МНК-оценок $\bar{\hat{X}} = \bar{X}$.

На больших выборках имеем

$$\hat{\beta}_1^{TSLs} \xrightarrow{p} \frac{\text{Cov}(Y_i, Z_i)}{\text{Cov}(X_i, Z_i)} = \frac{\text{Cov}(\beta_0 + \beta_1 X_i + u_i, Z_i)}{\text{Cov}(X_i, Z_i)} = \frac{\beta_1 \text{Cov}(X_i, Z_i)}{\text{Cov}(X_i, Z_i)} = \beta_1$$

То есть $\hat{\beta}_i^{TSLs}$ — состоятельная оценка.

Также на больших выборках

$$\begin{aligned} \hat{\beta}_1^{TSLs} &\sim N\left(\beta_1, \sigma_{\hat{\beta}_1^{TSLs}}^2\right) \\ \sigma_{\hat{\beta}_1^{TSLs}}^2 &= \frac{1}{n} \frac{\text{Var}[(Z_i - \mu_Z)u_i]}{[\text{Cov}(Z_i, X_i)]^2} \end{aligned}$$

поэтому мы можем использовать t -статистики и т. д.

2.2. Обобщенная регрессия с инструментальными переменными

$$Y_i = \beta_0 + \beta_1 X_{1i} + \dots + \beta_k X_{ki} + \beta_{k+1} W_{1i} + \dots + \beta_{k+r} W_{ri} + u_i, i = 1, \dots, n$$

- Y_i — зависимая переменная,
- $X_{1i}, \dots, X_{ki}$ — эндогенные регрессоры, коррелированные с u_i ,
- $W_{1i}, \dots, W_{ri}$ — экзогенные регрессоры, не коррелированные с u_i ,
- u_i — ошибка регрессии,
- $Z_{1i}, \dots, Z_{mi}$ — инструментальные переменные.

Если

$m = k$ коэффициенты модели *точно определены*,

$m > k$ коэффициенты модели *переопределены*,

$m < k$ коэффициенты модели *недоопределены*

Мы можем оценивать обобщенную регрессию с инструментальными переменными, только если коэффициенты точно или переопределены.

Инструменты Z_{ji} должны удовлетворять двум требованиям:

релевантность переменные $\hat{X}_{1i}, \dots, \hat{X}_{ki}, W_{1i}, \dots, W_{ri}$ и константа не должны быть совершенно мультиколлинеарными. Если $k = 1$, то для релевантности необходимо, чтобы в регрессии первого шага был хотя бы один ненулевой коэффициент.

экзогенность инструменты не должны быть коррелированы с ошибкой: $\text{Cov}(u_i, Z_{ji}) = 0, \forall j$.

2.2.1. Оценивание коэффициентов

Шаг 1 «очистка» эндогенных переменных: оцениваем при помощи МНК регрессии *каждого* X_{ji} на

- константу,
- все инструменты Z_{ji} ,
- все экзогенные переменные W_{ji} .

Получаем «очищенные» $\hat{X}_{ji}$.

На практике производится оценивание модели вида

$$X = Z\Pi + U$$

где

X — матрица, включающая в себя столбец из единиц (свободный член), эндогенные и экзогенные переменные;

Z — матрица, включающая в себя столбец из единиц (свободный член), экзогенные и инструментальные переменные.

Включение экзогенных переменных в матрицу X не противоречит приведенному описанию, так как при получении МНК-оценок

$$\hat{\Pi} = (Z'Z)^{-1}Z'X$$

в соответствующем столбце матрицы оцененных коэффициентов $\hat{\Pi}$ будут нули с единственной единицей, соответствующей экзогенной переменной. Это видно на следующем простейшем примере¹:

```
import numpy as np
np.random.seed(31415926)

# 150 нормально распределенных значений с дисперсией 0.01.
u = np.random.normal(size=150, scale=0.1)

# Матрица 150 x 3, первый столбец состоит из единиц,
# второй и третий столбцы --- N(0, 1).
Z = np.empty((150, 3))
Z[:, 0] = 1.
Z[:, 1:] = np.random.normal(size=(150, 2))

# Матрица 150 x 3.
# Второй и третий столбцы Z и X совпадают.
# Первый столбец равен:
# X = 0.5 + 1. * Z[1] + 2. * Z[2] + u
X = Z.copy()
X[:, 0] = Z @ np.array([0.5, 1, 2]) + u

print(np.round(
    np.linalg.inv(Z.T @ Z) @ Z.T @ X,
    6)
)
```

```
[[ 0.499924 -0.      -0.    ]
 [ 1.000069  1.      0.    ]
 [ 1.988546  0.      1.    ]]
```

Обратите внимание на оцененные коэффициенты, близкие к заданным нами, в первом столбце и нули с единицами во втором и третьем столбцах.

Подобранные значения равны

$$\hat{X} = Z\hat{\Pi} = Z(Z'Z)^{-1}Z'X = P_Z X$$

Отметим, что матрица P_Z симметрична и идемпотентна, то есть $P_Z P_Z = P_Z$.

¹К сожалению, Numpy поддерживает и поощряет неаккуратное отношение к размерностям перемножаемых массивов. В частности, в нашем случае на определенном этапе мы перемножаем двумерную матрицу с одномерным массивом, получая на выходе одномерный массив. Это может помочь вам «выстрелить себе в ногу», будьте внимательны!

Шаг 2 при помощи МНК оцениваем

$$Y_i = \beta_0 + \beta_1 \hat{X}_{1i} + \dots + \beta_k \hat{X}_{ki} + \beta_{k+1} W_{1i} + \dots + \beta_{k+r} W_{ri} + u_i$$

или

$$Y = \hat{X}\beta + u$$

С учетом сказанного выше оценка $\hat{\beta}^{TSLs}$ равна

$$\begin{aligned}\hat{\beta}^{TSLs} &= (\hat{X}'\hat{X})^{-1}\hat{X}'Y = \\ &= (X'P_ZX)^{-1}X'P_ZY = *\end{aligned}$$

Если модель определена точно, то матрицы $X'Z$ и $Z'X$ квадратные и, следовательно, потенциально обратимые. В этом случае выражение для $\hat{\beta}^{TSLs}$ можно упростить

$$\begin{aligned}* &= (X'Z(Z'Z)^{-1}Z'X)^{-1}X'Z(Z'Z)^{-1}Z'Y = \\ &= (Z'X)^{-1}(Z'Z)(X'Z)^{-1}(X'Z)(Z'Z)^{-1}Z'Y = \\ &= (Z'X)^{-1}Z'Y\end{aligned}$$

На больших выборках имеем

$$\begin{aligned}\hat{\beta}^{TSLs} &= (X'P_ZX)^{-1}X'P_Z(X\beta + u) = \beta + (X'P_ZX)^{-1}X'P_Zu \\ \frac{1}{n}X'P_ZX &\xrightarrow[n \rightarrow \infty]{p} \Sigma_{\hat{X}} \\ \frac{1}{n}X'P_Zu &\xrightarrow[n \rightarrow \infty]{p} \Sigma_{\hat{X}u} = 0 \\ \hat{\beta}^{TSLs} &\xrightarrow[n \rightarrow \infty]{p} \beta\end{aligned}$$

2.2.2. Предположения обобщенной регрессии с инструментальными переменными

- 1) $E(u_i | W_{1i}, \dots, W_{ri}) = 0$.
- 2) $(X_{1i}, \dots, X_{ki}, W_{1i}, \dots, W_{ri}, Z_{1i}, \dots, Z_{mi}, Y_i) \sim \text{i.i.d.}$
- 3) Большие выбросы маловероятны: X, Y, Z, W имеют ненулевые конечные четвертые моменты.
- 4) **Выполняются условия допустимости инструментов.**

При выполнении этих предположений IV-оценки коэффициентов состоятельны и нормально распределены в больших выборках.

2.3. Тестирование слабых инструментов

Слабые инструменты — объясняющие малую часть изменений X . 2МНК оценки имеют смещение и не имеют нормального распределения.

Построим F -статистику для проверки гипотезы о равенстве нулю всех коэффициентов при инструментах в регрессии первого шага 2МНК.

Если эта F -статистика меньше 10, то набор инструментов — слабый.

2.4. Тестирование сверхидентифицирующих ограничений

Данный тест призван ответить на следующий вопрос: является ли использованный набор инструментов «годным», то есть некоррелированы ли входящие в него инструменты со случайной ошибкой².

Строго говоря, на этот вопрос можно дать какой-то ответ **только** при наличии сверхидентификации, так как в этом случае у нас, в общем случае, бесконечное количество способов идентифицировать параметры модели, что дает нам «пространство для маневра».

Пусть $\hat{u}_i^{TSLS}$ — остатки 2МНК регрессии. Оценим модель

$$\hat{\mathbf{u}}^{TSLS} = \mathbf{Z}\boldsymbol{\delta} + \mathbf{W}\boldsymbol{\lambda} + \boldsymbol{\nu}$$

и протестируем следующую нулевую гипотезу

$$\boldsymbol{\delta} = \mathbf{0}$$

или

$$\delta_1 = \dots = \delta_m = 0$$

Для тестирования данной гипотезы можно воспользоваться следующими статистиками:

- $J = nR_u^2 \sim \chi_{m-k}^2$, где R_u^2 — нецентрированный³ коэффициент детерминации во вспомогательной регрессии.
- $J = mF \sim \chi_{m-k}^2$, где F — F -статистика для приведенной выше нулевой гипотезы.

Если мы получаем слишком большое значение J -статистики, то мы отвергаем нулевую гипотезу. В этом случае мы можем говорить о том, что *некоторые* используемые нами инструменты экзогенны, то есть не годны.

²Подробнее смотрите Цыплаков «Экскурс в мир инструментальных переменных»

³Сомнительное утверждение, но поверим тов. Цыплакову.